倒立摆控制：从拉格朗日到 Transformer

一部可以逐行验证的教程

建模 · 经典控制 · 模仿学习 · Transformer 从零实现 · 强化学习

写在前面

这本书只讲一件事：**如何把一台小车倒立摆，从一个物理系统变成一个有理论依据、能实时运行的控制器**，并且让每一步都可以被验证。

全书分成三篇，对应三种完全不同的方法论：

篇	方法论	答案的形状
第一篇（第 1–6 章）	经典非线性控制	一个解析控制律
第二篇（第 7–10 章）	模仿学习与强化学习	一个 18k 参数的神经网络
第三篇（第 11–17 章）	从零实现这个网络	前向、反向、优化器的每一行代码

怎么读

- **只有控制背景**：读第一篇（1–6 章），它是全书的动机来源——LQR 的能力边界（第 2 章）解释了为什么必须引入学习。
- **只有深度学习背景**：先读第 1 章拿到模型，再直接跳到第二篇。
- **想搞懂 Transformer 本身**：第三篇（11–17 章）是完整的从零实现，包含手写反向传播与 autograd 的逐位对齐（梯度差 3×10^{-14}）。
- **想动手**：仓库里的 `index.html` 是交互式报告，浏览器里可实时看四种控制器同台对比；`build/` 与 `tutorial/code/` 是可复现的代码。

关于“第 N 讲”

章标题里的“第 N 讲”是配套视频的编号（共 18 集，见附录 B）。章号由排版自动生成，与讲号不同——比如第一篇的第 1 章就是“第 1 讲”。

可验证性

本书的每个关键数字都来自可重跑的代码，而不是估计：

- 闭环指标：60 组随机初值、12 s、统一成功判据（第 9 章）；
- 手写反向：与 autograd 的差 3×10^{-14}，另用中心差分独立复核（第 13 章）；
- 优化器对比：同模型同初始化，含发散案例（第 15 章）。

目录

写在前面 **ii**

第一部分　建模与经典控制 **1**

第一章　建模 **2**

1.1　为什么从这一台小车开始 2

1.2　系统、坐标与假设 3

1.2.1　三条建模假设，以及它们的代价 3

1.3　拉格朗日建模 4

1.3.1　运动学 4

1.3.2　动能、势能与耗散 4

1.3.3　Euler–Lagrange 方程 4

1.3.4　解出加速度 5

1.3.5　三条结构性事实 6

1.4　能量：把一个控制目标压缩成标量 6

1.5　平衡点与线性化 7

1.5.1　平衡点 7

1.5.2　在直立点线性化 7

1.5.3　特征值与不稳定度 8

1.5.4　线性化到底能信多远 8

1.5.5　可控，但不等于随心所欲 8

1.6　数值实现 8

1.6.1　RK4 积分器 8

1.6.2　三项自检 9

1.7 五个常见陷阱 10
1.8 本讲小结 10
习题 10
延伸阅读 11

第二章 线性基线 **12**
2.1 为什么先做线性控制 12
2.2 从 Riccati 方程到增益 12
2.2.1 问题设定 12
2.2.2 本课的具体选择 13
2.2.3 增益的直觉 13
2.3 局部表现有多好 14
2.4 吸引域：把” 局部” 画出来 14
2.4.1 定义与算法 14
2.4.2 读图 15
2.5 全局失败：25% 与 82% 16
2.5.1 失败是怎么发生的 16
2.5.2 一个反直觉的现象 16
2.6 Q/R 怎么选：三组设计的对比 16
2.7 从失败读出设计需求 17
2.8 本讲小结 17
习题 17
延伸阅读 18

第三章 反馈线性化 **19**
3.1 为什么值得换坐标 19
3.2 相对阶：为什么只挑小车通道 20
3.3 反解之后系统长什么样 20
3.4 精度验证 20
3.5 奇异点：摆杆通道会失去权限 21
3.6 ” 换坐标” 到底带来多少好处 21
3.7 本讲小结 21
习题 22

延伸阅读 22

第四章 能量整定 **23**

4.1 能量通道 23
4.2 控制律与 Lyapunov 证明 23
4.3 LaSalle 与”下垂陷阱” 24
4.4 为什么必须加”小车回中” 24
4.5 增益 k_E：泵多快，撞多狠 25
4.6 实测：一次完整的摆起 25
4.7 本讲小结 25
习题 26
延伸阅读 26

第五章 滑模 **27**

5.1 从”相信模型”到”规定流形” 27
5.2 到达律 27
5.3 解出加速度指令 28
5.4 边界层与抖振 28
5.5 一个真实的坑：小车会跑 28
5.6 抗扰实测 29
5.7 本讲小结 29
习题 29
延伸阅读 30

第六章 切换与监督 **31**

6.1 两种”局部真理” 31
6.2 捕获窗口：多大才接得住 31
6.3 迟滞：防止在边界上抖 32
6.4 切换瞬态：11 N 的单步跳变 32
6.5 监督器设计清单 32
6.6 本讲小结 32
习题 33
延伸阅读 33

第二部分 从数据到 Transformer **34**

第七章 数据与模仿 **35**

7.1 为什么这是监督学习问题 . . . 35
7.1.1 但为什么它不是普通监督学习 . . . 35
7.1.2 还有第三个坑：专家有记忆 . . . 35
7.2 历史窗口作为充分统计量 . . . 36
7.2.1 为什么窗口能替代隐状态 . . . 36
7.2.2 $H = 24$ 的定量依据 . . . 36
7.2.3 采样与混叠 . . . 36
7.3 监督目标：我们到底在最小化什么 . . . 37
7.3.1 闭式解是条件均值 . . . 37
7.3.2 归一化为什么重要 . . . 37
7.4 分布漂移：定量估计 . . . 37
7.4.1 为什么误差会自己长大 . . . 37
7.4.2 经典界：T^2 与 T . . . 38
7.4.3 本用例的实测 . . . 38
7.5 数据覆盖：噪声该加多大 . . . 38
7.6 本讲小结 . . . 38
习题 . . . 39
延伸阅读 . . . 39

第八章 Transformer 策略 **40**

8.1 问题的形状 . . . 40
8.2 注意力：把” 回看” 写成可微检索 . . . 40
8.2.1 软检索 . . . 40
8.2.2 $\sqrt{d}$ 是从哪来的 . . . 40
8.2.3 因果掩码 . . . 41
8.3 为什么不是 MLP 或 RNN . . . 41
8.4 参数量：一项一项数 . . . 42
8.5 训练 . . . 42
8.6 部署：int8 量化的误差界 . . . 42
8.6.1 仿射量化 . . . 42

8.6.2 误差怎么传到输出 . . . 43
8.6.3 推理成本 . . . 43
8.7 它到底在看什么（实测） . . . 43
8.8 本讲小结 . . . 43
习题 . . . 44
延伸阅读 . . . 44

第九章 DAgger 与评测 **45**
9.1 把”分布漂移”写成公式 . . . 45
9.1.1 误差累积引理 . . . 45
9.2 DAgger：把策略自己的状态放进训练集 . . . 46
9.2.1 为什么这能把 T^2 降成 T . . . 46
9.2.2 本用例的两轮 . . . 46
9.3 评测的统计学 . . . 46
9.3.1 成功率的置信区间 . . . 46
9.3.2 需要多少样本 . . . 47
9.3.3 三个偏差来源 . . . 47
9.4 本讲小结 . . . 47
习题 . . . 47
延伸阅读 . . . 48

第十章 强化学习微调 **49**
10.1 MDP 与目标 . . . 49
10.2 策略梯度定理 . . . 49
10.2.1 本课的策略参数化 . . . 50
10.3 PPO：为什么是 clip . . . 50
10.3.1 重要性采样 . . . 50
10.3.2 从信任域到 clip . . . 50
10.4 GAE：优势估计的偏差-方差权衡 . . . 50
10.5 奖励设计与它的性质 . . . 51
10.5.1 为什么写物理量而不是指标 . . . 51
10.5.2 奖励整形不改变最优策略 . . . 51
10.6 域随机化 = 分布鲁棒优化 . . . 51

10.7 结果与帕累托 . . . 52
10.8 本讲小结 . . . 52
习题 . . . 52
延伸阅读 . . . 53

第三部分 Transformer 从零实现 54

第十一章 为什么长这样：从 RNN 到注意力 55
11.1 序列建模的三代方案 . . . 55
11.2 RNN 的两个硬伤 . . . 55
11.3 检索视角：注意力到底是什么 . . . 55
11.4 数据流与张量形状 . . . 56
11.5 一个必须强调的约束：因果性 . . . 56

第十二章 前向与反向：公式与雅可比 57
12.1 LayerNorm . . . 57
12.2 多头因果注意力 . . . 57
12.3 GELU . . . 58
12.4 残差与输出头 . . . 58

第十三章 纯 numpy 实现 59
13.1 代码骨架 . . . 59
13.2 五个易错点 . . . 59
13.3 与 autograd 逐位对齐 . . . 60

第十四章 torch 实现与训练对比 61
14.1 等价结构 . . . 61
14.2 训练对比 . . . 61

第十五章 训练方法：从 SGD 到 AdamW 63
15.1 为什么普通梯度下降不够 . . . 63
15.2 动量 . . . 63
15.3 RMSProp：逐参数步长 . . . 63
15.4 Adam 与偏差修正 . . . 64

15.5 AdamW：解耦权重衰减 64
15.6 学习率调度 64
15.7 实测对比 64

第十六章 结果可视化与落地 **66**
16.1 加载生产权重：一致性散点 66
16.2 注意力热图 68
16.3 梯度量级 68

第十七章 习题与代码索引 **69**
代码索引 69

第十八章 DAgger：从原理到实现 **70**
18.1 问题的形式化 70
18.1.1 误差累积 70
18.2 算法 70
18.3 实现 71
18.4 实测 71
18.4.1 一个反直觉的现象 71
18.5 习题 72

第十九章 PPO：从原理到实现 **73**
19.1 MDP 73
19.2 策略梯度定理 73
19.3 GAE 74
19.4 PPO 的 clip 目标 74
19.5 实现：七行核心 74
19.5.1 优势标准化为什么重要 74
19.6 实测 75
19.6.1 域随机化 75
19.7 习题 75

第四部分 附录 **76**

附录 A Transformer 内部机制 **77**

A.1 全链路框图 . . . 78
A.2 逐步前向：真实数值 . . . 78
A.2.1 嵌入与位置编码 . . . 78
A.2.2 LayerNorm . . . 79
A.2.3 QKV 与分头 . . . 79
A.2.4 因果掩码与 softmax . . . 79
A.2.5 加权求和、残差与 FFN . . . 79
A.2.6 输出 . . . 80
A.3 反向传播：梯度怎么流回去 . . . 80
A.3.1 损失与链式法则 . . . 80
A.3.2 输出层的梯度 . . . 80
A.3.3 LayerNorm 的梯度 . . . 80
A.3.4 Softmax 的雅可比 . . . 81
A.3.5 注意力的完整反传 . . . 81
A.3.6 本用例的梯度量级（实测） . . . 81
A.3.7 参数更新 . . . 81
A.4 注意力与倒立摆运动：把两条时间轴对起来 . . . 82
A.4.1 统计 . . . 82
A.4.2 怎么看这张图 . . . 82
A.5 本附录小结 . . . 83
习题 . . . 83
延伸阅读 . . . 83

附录 B 资源索引：代码、视频与交互式报告 **84**

B.1 代码 . . . 84
B.2 视频（20 集，约 60 分钟） . . . 84
B.3 交互式报告 . . . 85

第一部分

建模与经典控制

第一章　第 1 讲　建模：把一台机器写成方程

本讲目标　从零推导出小车倒立摆的运动方程，理解三件事：为什么它难（欠驱动、非线性、不稳定）、为什么它可解（小车通道恒可逆）、以及后面每一讲都要反复用到的两个工具——能量与线性化。

前置　拉格朗日力学（会用即可）、矩阵、常微分方程。

视频　约 4 分钟（成片 3:43）。　**代码**　`build/plant.py`。

1.1　为什么从这一台小车开始

控制课的例子很多，但很少有系统能同时具备下面四条性质：

1. **欠驱动**：两个自由度（小车位置 p、摆杆角度 θ），只有一个输入（作用在小车上的力 u）。你无法直接” 命令” 摆杆怎么转。

2. **本质非线性**：方程里出现 $\sin\theta$、$\cos\theta$、$\dot{\theta}^2$ 的乘积，线性近似只在十几度的范围内有效。

3. **开环不稳定**：直立平衡点的线性化有一个正实特征值，微小偏差会以 $0.25\,\mathrm{s}$ 的时间常数指数放大。

4. **可实验**：它便宜、安全、能 $50\,\mathrm{Hz}$ 实时跑，适合把所有结论都验证一遍。

前三条决定了它” 不好控”，第四条决定了它” 适合教学”。后面的十讲会反复出现一个模式：**先看一个方法在哪里失效，再去理解为什么需要下一个方法**。

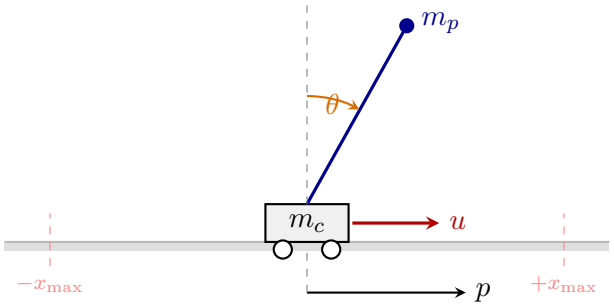


图 1.1: 坐标约定。θ 从**竖直向上**量起，摆杆向右倾为正；p 是小车位置，向右为正；u 是作用在小车上的水平力。l 是转轴到摆杆质心的距离。

1.2 系统、坐标与假设

符号	含义	本课取值
p	小车位置（导轨中心为原点）	–
θ	摆杆与竖直向上方向的夹角，右倾为正	–
u	作用在小车上的水平力	$\lvert u\rvert \le 12\,\mathrm{N}$
$m_c,\ m_p$	小车质量、摆杆（等效质点）质量	$1.00,\ 0.25\,\mathrm{kg}$
l	转轴到摆杆质心的距离	$0.60\,\mathrm{m}$
$b_c,\ b_p$	导轨 / 转轴处的粘性阻尼系数	$0.12,\ 0.004$
g	重力加速度	$9.81\,\mathrm{m/s^2}$
$x_{\max}$	导轨半长（超出即撞墙）	$2.40\,\mathrm{m}$
Δt	控制与积分周期	$20\,\mathrm{ms}$

1.2.1 三条建模假设，以及它们的代价

1. **摆杆视为质点**：质量集中在离转轴 l 处。真实均质杆的转动惯量是 $I = \frac{1}{3}m_pL^2$（L 为全长），等效办法是把 l 换成 $l_{\text{eff}} = \frac{2}{3}L$ 并在动能里加 I 项。本课用质点模型，因为**它让公式短一半，而不改变任何控制结构**。

2. **无滑动、无间隙**：小车与导轨之间只有粘性摩擦，没有干摩擦和间隙。

3. **力直接作用在小车上**：忽略电机电枢动态与传动柔性。

坑 这三条假设都不是”对不对”的问题，而是”后面会不会被打破”的问题。第 10 讲会看到：改用域随机化训练的策略，对 m_p 变化 $\pm 20\%$ 依然能站住；而线性控制器在设计点之外会明显退化。

1.3 拉格朗日建模

1.3.1 运动学

摆杆质心的位置由小车位置和摆角共同决定：

$$x_p = p + l\sin\theta, \qquad y_p = l\cos\theta. \tag{1.1}$$

对时间求导，得质心速度

$$\dot{x}_p = \dot{p} + l\dot{\theta}\cos\theta, \qquad \dot{y}_p = -l\dot{\theta}\sin\theta. \tag{1.2}$$

1.3.2 动能、势能与耗散

系统的动能为小车平动动能与摆杆质心平动动能之和（质点模型无转动动能）：

$$\begin{aligned} T &= \tfrac{1}{2}m_c\dot{p}^2 + \tfrac{1}{2}m_p\big[(\dot{p} + l\dot{\theta}\cos\theta)^2 + (l\dot{\theta}\sin\theta)^2\big] \\ &= \tfrac{1}{2}(m_c + m_p)\dot{p}^2 + m_p l\cos\theta\,\dot{p}\dot{\theta} + \tfrac{1}{2}m_p l^2\dot{\theta}^2. \end{aligned} \tag{1.3}$$

注意第二项 $m_p l\cos\theta\,\dot{p}\dot{\theta}$：**这就是两个自由度耦合的地方**。它意味着推小车会改变摆杆的运动，反之亦然。后面所有”耦合项补偿”都在处理它。

以转轴为势能零点，摆杆的势能为

$$V = m_p g\, y_p = m_p g l\cos\theta. \tag{1.4}$$

竖直向上（$\theta = 0$）时势能最大，这就是它不稳定的来源。

摩擦用 Rayleigh 耗散函数描述：

$$R = \tfrac{1}{2}b_c\dot{p}^2 + \tfrac{1}{2}b_p\dot{\theta}^2. \tag{1.5}$$

1.3.3 Euler–Lagrange 方程

广义坐标 $q = (p, \theta)$，广义力 $Q = (u, 0)$，运动方程为

$$\frac{d}{dt}\frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} + \frac{\partial R}{\partial \dot{q}_i} = Q_i, \qquad L = T - V. \tag{1.6}$$

对 p 分量。先算两个偏导：

$$\frac{\partial L}{\partial \dot{p}} = (m_c + m_p)\dot{p} + m_p l\cos\theta\,\dot{\theta}, \tag{1.7}$$

$$\frac{\partial L}{\partial p} = 0. \tag{1.8}$$

对第一个式子求全导数时要小心：$\cos\theta$ 是时变的，

$$\frac{d}{dt}\frac{\partial L}{\partial \dot{p}} = (m_c + m_p)\ddot{p} + m_p l\cos\theta\,\ddot{\theta} - m_p l\sin\theta\,\dot{\theta}^2. \tag{1.9}$$

代入 (1.6)，加上耗散项 $b_c\dot{p}$，得到

$$(m_c+m_p)\ddot{p}+m_pl\cos\theta\,\ddot{\theta}-m_pl\sin\theta\,\dot{\theta}^2=u-b_c\dot{p}. \tag{1.10}$$

对 θ 分量。

$$\frac{\partial L}{\partial\dot{\theta}}=m_pl\cos\theta\,\dot{p}+m_pl^2\dot{\theta}, \tag{1.11}$$

$$\frac{\partial L}{\partial\theta}=-m_pl\sin\theta\,\dot{p}\dot{\theta}+m_pgl\sin\theta. \tag{1.12}$$

同样求全导数：

$$\frac{d}{dt}\frac{\partial L}{\partial\dot{\theta}}=m_pl\cos\theta\,\ddot{p}-m_pl\sin\theta\,\dot{p}\dot{\theta}+m_pl^2\ddot{\theta}. \tag{1.13}$$

两式相减时，$-m_pl\sin\theta\dot{p}\dot{\theta}$ 恰好抵消，这是非常好的一个巧合（来源是耦合项的对称性）。加上 $b_p\dot{\theta}$：

$$m_pl\cos\theta\,\ddot{p}+m_pl^2\ddot{\theta}+m_pgl\sin\theta=-b_p\dot{\theta}. \tag{1.14}$$

式 (1.10) 和 (1.14) 是整个课程的出发点。后面每一讲都会回到这两行：第 3 讲在它们上面做反解，第 4 讲对它们做能量求导，第 5 讲把它们化成滑模面。

1.3.4 解出加速度

控制器需要的是”给定 u，加速度是多少”，所以要把两个方程联立解出 $\ddot{p}$ 与 $\ddot{\theta}$。由 (1.14) 解出

$$\ddot{\theta}=\frac{1}{l}\Big(g\sin\theta-\cos\theta\,\ddot{p}-\frac{b_p\dot{\theta}}{m_pl}\Big), \tag{1.15}$$

代回 (1.10) 并整理（把含 $\ddot{p}$ 的项归并到左边）：

$$\big(m_c+m_p\sin^2\theta\big)\,\ddot{p}=u-b_c\dot{p}+m_pl\sin\theta\,\dot{\theta}^2+b_p\cos\theta\,\dot{\theta}-m_pg\sin\theta\cos\theta. \tag{1.16}$$

于是得到最终的状态方程：

$$\boxed{\begin{aligned}\ddot{p}&=\frac{u-b_c\dot{p}+m_pl\sin\theta\,\dot{\theta}^2+b_p\cos\theta\,\dot{\theta}-m_pg\sin\theta\cos\theta}{m_c+m_p\sin^2\theta}, &(1.17)\\ \ddot{\theta}&=\frac{g\sin\theta-\ddot{p}\cos\theta-b_p\dot{\theta}/(m_pl)}{l}. &(1.18)\end{aligned}}$$

写成状态空间形式，取状态 $x=(p,\theta,\dot{p},\dot{\theta})\in\mathbb{R}^4$：

$$\dot{x}=f(x,u),\qquad f(x,u)=\big(\dot{p},\ \dot{\theta},\ \ddot{p},\ \ddot{\theta}\big). \tag{1.19}$$

1.3.5 三条结构性事实

命题 1.1 (小车通道恒可逆)**.** *式 (1.17) 的分母满足*

$$m_c + m_p \sin^2\theta \ \in\ \big[m_c,\ m_c + m_p\big] = [1.00,\ 1.25] \tag{1.20}$$

对一切 θ 成立，永不接近零。

这条性质看起来平淡，其实是第 3 讲全部技巧的基础：它意味着**我们可以精确地反解出" 让小车产生指定加速度需要多大力"**，而且这个反解在整个工作空间内都良态。

命题 1.2 (摆杆通道会失去权限)**.** *式 (1.15) 中 $\ddot{p}$ 的系数是 $\cos\theta$。当 $\theta \to \pm 90^\circ$ 时 $\cos\theta \to 0$，此时无论小车怎么加速，都几乎无法改变摆杆的角加速度。*

这就是" 欠驱动" 的具体形态：摆杆在水平位置附近，输入对它的影响是二阶小量。

命题 1.3 (输入只有一个)**.** *u 只出现在 $\ddot{p}$ 的分子里，且系数为 1。摆杆方程里没有直接的 u——它只能通过 $\ddot{p}$ 被间接影响。*

最后这条决定了一个硬约束：**不能同时独立指定 p 和 θ 的轨迹**。第 3 讲会把它写成一条关于" 解耦矩阵不可逆" 的精确陈述。

1.4 能量：把一个控制目标压缩成标量

定义摆杆相对能量的（以竖直向上静止为零点）

$$E(x) = \tfrac{1}{2} m_p l^2 \dot{\theta}^2 + m_p g l(\cos\theta - 1). \tag{1.21}$$

它满足

$$E = 0 \iff \text{摆杆静止于竖直向上}, \qquad E = -2m_p g l = -2.943\ \text{J} \iff \text{静止下垂}. \tag{1.22}$$

注 1.4. *E 是**摆杆在转轴坐标系下的能量**，不是系统的总能量。它不是守恒量：小车一加速，E 就会变。事实上第 4 讲的全部内容就是**利用这一点**——用小车加速度去" 泵" 这个能量。*

*数值感受一下：无摩擦、无驱动、从 $\theta_0 = 2.5\,rad$ 释放摆动 $20\,s$，E 在 -2.650 到 $-2.577\,J$ 之间来回变化，而同一时间段里**总能量**守恒到 10^{-8} 的相对精度。两者都不是" 错的"，只是问题不同。*

总能量（用于数值自检）为

$$E_{\text{tot}} = \tfrac{1}{2} m_c \dot{p}^2 + \tfrac{1}{2} m_p \big[(\dot{p} + l\dot{\theta}\cos\theta)^2 + (l\dot{\theta}\sin\theta)^2\big] + m_p g l \cos\theta. \tag{1.23}$$

1.5 平衡点与线性化

1.5.1 平衡点

令 $\dot p=\dot\theta=\ddot p=\ddot\theta=0$。由 (1.14) 得 $g\sin\theta=0$，即

$$\theta\in\{0,\ \pi\},\tag{1.24}$$

而 p 可以取任意值（没有位置反馈时）。所以平衡点是一个**连续集**：$\{(p,0,0,0)\}$（直立，不稳定）与 $\{(p,\pi,0,0)\}$（下垂，稳定）。

1.5.2 在直立点线性化

取 $\theta=\delta\theta$、$\dot\theta=\delta\dot\theta$ 等为小量，用 $\sin\theta\approx\theta$、$\cos\theta\approx1$、$\dot\theta^2\approx0$、$\sin\theta\cos\theta\approx\theta$，在 (1.17)(1.18) 中得到

$$\ddot p=\frac{u-b_c\dot p+b_p\dot\theta-m_pg\,\theta}{m_c},\tag{1.25}$$

$$\ddot\theta=\frac{g\theta-\ddot p-b_p\dot\theta/(m_pl)}{l}.\tag{1.26}$$

把第一式代入第二式，得到 $\dot{\delta x}=A\,\delta x+B\,\delta u$，其中

$$\boxed{A=\begin{bmatrix}0&0&1&0\\0&0&0&1\\0&-\dfrac{m_pg}{m_c}&-\dfrac{b_c}{m_c}&\dfrac{b_p}{m_c}\\0&\dfrac{g}{l}&\dfrac{b_c}{m_cl}&-\dfrac{1}{l}\Big(\dfrac{b_p}{m_c}+\dfrac{b_p}{m_pl}\Big)\end{bmatrix},\qquad B=\begin{bmatrix}0\\0\\1\\-\dfrac{1}{l}\end{bmatrix}\cdot\frac{1}{m_c}.}\tag{1.27}$$

代入本课参数，得到两个具体的矩阵：

$$A=\begin{bmatrix}0&0&1&0\\0&0&0&1\\0&-2.4525&-0.1200&0.0040\\0&16.3500&0.2000&-0.0511\end{bmatrix},\qquad B=\begin{bmatrix}0\\0\\1.0000\\-1.6667\end{bmatrix}.\tag{1.28}$$

坑 这里有两个几乎所有人都漏过的项，务必检查一遍：

- $A_{32}=-\dfrac{m_pg}{m_c}\approx-2.45$：**摆杆也会拉小车**。只看 (1.17) 的分子容易漏掉，因为它是"$-\theta$ 引起的加速度"。
- A_{44} 不是 $-\dfrac{b_p}{m_cl}$，而是 $-\dfrac{1}{l}\big(\dfrac{b_p}{m_c}+\dfrac{b_p}{m_pl}\big)\approx-0.051$：转轴摩擦同时通过 $\ddot p$ 间接进入 $\ddot\theta$，所以出现了两次。

作者在本项目的第一版代码里就漏了这两项，得到的 K 与正确值相差 5%–8%。线性控制器照样能稳住，所以**这个错误不会被"能不能站起来"发现**——只能靠推导和数值校验发现。

1.5.3 特征值与不稳定度

A 的特征值为

$$\lambda = 0, \quad +4.0034, \quad -4.0845, \quad -0.0900. \tag{1.29}$$

这里有两个信息：

- **一个正实根** $+4.00$：开环不稳定，时间常数 $1/4.00 = 0.25\,\mathrm{s}$。直观含义是：偏差每 $0.25\,\mathrm{s}$ 放大 $e \approx 2.7$ 倍，或者说**每** $0.17\,\mathbf{s}$ **翻倍**。数值上，1° 的初始倾角在 $0.5\,\mathrm{s}$ 内长到 4.8°。
- **一个** 0 **特征值**：对应小车位置本身（没有位置反馈时位置漂移不失稳）。这个零特征值是第 2 讲里 Q 必须给位置项权重的根本原因。

1.5.4 线性化到底能信多远

数值实验：从 $\theta_0 = 0.02\,\mathrm{rad}$ 出发、无驱动，比较非线性仿真与线性化预测。$1\,\mathrm{s}$ 后非线性给出 $0.8456\,\mathrm{rad}$，而线性化预测 $0.5534\,\mathrm{rad}$，**相差** 35%。原因很直接：$0.85\,\mathrm{rad}$ 已接近 50°，$\sin\theta \approx \theta$ 早就失效了。

把初值缩小到 $10^{-4}\,\mathrm{rad}$ 再看增长率：仿真拟合得到 $3.96\,\mathrm{s}^{-1}$，理论值 $4.00\,\mathrm{s}^{-1}$，误差 1%。

结论：线性化可以精确描述**局部**行为（增长率、极点位置），但不能用来预测**大范围**行为。这解释了第 2 讲里 LQR 的” 能力边界”——不是控制器不好，是模型在那之外不再成立。

1.5.5 可控，但不等于随心所欲

可控性矩阵

$$\mathcal{C} = \begin{bmatrix} B, & AB, & A^2B, & A^3B \end{bmatrix} \in \mathbb{R}^{4\times 4} \tag{1.30}$$

的行列式非零（数值秩为 4），所以系统在直立点**完全可控**：存在反馈使四个状态都以任意速度收敛。

但可控不等于” 能任意指定两个输出”。设输出 $y = (p, \theta)$，求二阶导：

$$\ddot{y} = \begin{bmatrix} \ddot{p} \\ \ddot{\theta} \end{bmatrix} = \underbrace{\begin{bmatrix} 1/(m_c + m_p \sin^2\theta) \\ -\cos\theta / \big(l(m_c + m_p \sin^2\theta)\big) \end{bmatrix}}_{\text{解耦矩阵}\Delta(x)} u + \begin{bmatrix} \text{耦合项} \\ \text{耦合项} \end{bmatrix}. \tag{1.31}$$

$\Delta(x) \in \mathbb{R}^{2\times 1}$ 是一个列向量，秩至多为 1，**对任何** u **都不可能同时实现任意的** $(\ddot{p}, \ddot{\theta})$。这就是欠驱动的数学表述。第 3 讲会挑其中一个通道做精确线性化，另一个通道则留给” 能量” 或” 滑模” 去管。

1.6 数值实现

1.6.1 RK4 积分器

Listing 1.1: 核心仿真循环（节选，注释为英文以避免排版问题）

```python
def f(x, u, p):
    """Continuous-time dynamics xdot = f(x,u)."""
    pos, th, v, w = x
    s, c = np.sin(th), np.cos(th)
    den = p["m_c"] + p["m_p"] * s * s            # >= m_c > 0
    pdd = (u - p["b_c"] * v + p["m_p"] * p["l"] * s * w * w
           + p["b_p"] * c * w - p["m_p"] * p["g"] * s * c) / den
    wdd = (p["g"] * s - c * pdd - p["b_p"] * w / (p["m_p"] * p["l"])) / p["l"]
    return np.array([v, w, pdd, wdd])

def rk4(x, u, dt, p, substeps=2):
    h = dt / substeps
    for _ in range(substeps):                    # sub-stepping keeps energy honest
        k1 = f(x, u, p)
        k2 = f(x + 0.5 * h * k1, u, p)
        k3 = f(x + 0.5 * h * k2, u, p)
        k4 = f(x + h * k3, u, p)
        x = x + (h / 6.0) * (k1 + 2 * k2 + 2 * k3 + k4)
    return x
```

注意两件事：控制量的作用在子步之间**保持不变**（零阶保持），这正是真实数字控制器的行为；子步只提高积分精度，不改变控制律。

1.6.2 三项自检

一个仿真器写完之后，必须能通过下面三条检查，否则后面的结论全部不可信。

(1) 无摩擦、无驱动时总能量守恒。从 $\theta_0 = 2.5\,\mathrm{rad}$ 释放，跑 $20\,\mathrm{s}$：

每步子步数	总能量相对漂移	说明
2	4.8×10^{-8}	本课默认设置
4	1.5×10^{-9}	每加倍约降 32 倍（RK4 的四阶收敛）
8	4.8×10^{-11}	高精度参考

(2) 平衡点的稳定性方向要对。无摩擦、无驱动时：下垂点 ($\theta = \pi$) 停留不动；直立点 ($\theta = 0$) 的任何扰动都会指数放大。如果反过来，说明 θ 的符号约定或重力项写错了。

(3) 线性化预测与仿真的增长率一致。见 §1.5.4：3.96 对 4.00。

坑 不要用式 (1.21) 的 E 去做能量守恒自检。它不是系统的总能量，本来就不守恒（§1.4 的注）。这是我在第一版代码里排查了半小时的”假 bug”。

1.7 五个常见陷阱

1. **角度不做 wrap**。θ 在积分过程中会超过 $\pm\pi$。如果控制逻辑直接比较 $|\theta|$ 的大小，摆杆转过一圈后会被判定为" 远离直立"。本项目在浏览器端的实现里就因为这个 bug 把闭环成功率从 100% 算成了 83% ——**控制器没变，是判据错了**。
2. **把摆杆能量当成总能量**（见上文注）。
3. **线性化漏项**（见 §1.5.2 的坑）。
4. **点质量 vs 均质杆**。若摆杆是均质杆，$I = \frac{1}{3}m_pL^2$，此时等效摆长 $l_{\text{eff}} = \frac{2}{3}L$，且方程里的 m_pl^2 要换成 $m_pl^2 + I$。控制结构不变，但参数不对会导致稳定性边界偏移。
5. **单位与量纲**。b_p 的单位是 N·m·s/rad，$b_p/(m_pl)$ 才是角加速度量纲；写代码时把 b_p 直接丢进角速度方程是常见错误。

1.8 本讲小结

1. 用拉格朗日方程两行推导就得到了完整模型 (1.17)(1.18)，全部非线性都集中在 $\sin\theta, \cos\theta$ 和耦合项 $\dot\theta^2$。
2. 分母 $m_c + m_p\sin^2\theta \in [1.00, 1.25]$ 恒正 $\Rightarrow$ 小车通道永远可以精确反解。
3. $\cos\theta$ 是摆杆通道里 u 的系数 $\Rightarrow$ 水平位置" 失去权限"，这是欠驱动的根源。
4. $E = \frac{1}{2}m_pl^2\dot\theta^2 + m_pgl(\cos\theta - 1)$ 用一个标量概括了" 摆起来"，它是第 4 讲的核心工具；但它不守恒。
5. 线性化给出一个正实根 +4.00（时间常数 0.25 s）与一个零根，前者解释" 为什么难"，后者预告" 为什么 LQR 必须惩罚位置"。

习题

1. 从式 (1.10)(1.14) 出发，完整复现 (1.17)(1.18) 的推导，写出每一步合并了哪些项。
2. 把模型改成" 均质杆"：写出新的 T 与 V，给出 l_{eff} 与 I 的关系，并说明当 L 相同时，新的不稳定特征值比质点模型大还是小。
3. 证明 $A_{44} = -\frac{1}{l}\left(\frac{b_p}{m_c} + \frac{b_p}{m_pl}\right)$，并解释为什么是" 两次" 进入。提示：$\ddot\theta$ 显含 $\dot\theta$，而 $\ddot p$ 也显含 $\dot\theta$。
4. 用数值实验画出" 线性化误差随初始角度" 的曲线：θ_0 从 10^{-3} 到 0.5 rad，1 s 后的相对误差。找出误差达到 5% 的角度。
5. 计算并画出解耦矩阵 $\Delta(x)$ 的范数随 θ 的变化，说明在什么角度下小车加速度对摆杆" 几乎失效"。

6.（编程）实现 (1.17)(1.18) 并用三个自检验证你的仿真器；然后把 b_c, b_p 置零，测 20 s 总能量漂移，解释它随子步数的收敛阶。

延伸阅读

- K. J. Åström, K. Furuta, *Swinging up a pendulum by energy control*, Automatica, 2000.（第 4 讲的源头）
- R. Tedrake, *Underactuated Robotics*（MIT 课程讲义），第 3 章对欠驱动与可控性有更系统的讨论。
- S. Fantoni, R. Lozano, *Non-linear Control for Underactuated Mechanical Systems*, Springer, 2002.

第二章　第 2 讲　线性基线：LQR 与它的能力边界

本讲目标　用最简单的办法把摆” 扶住”：在直立点做线性二次型最优控制。更要紧的是把它的**能力边界**画出来——吸引域长什么样、全局成功率是多少、失败是怎么失败的。这条边界会决定后面八讲的全部设计动机。

前置　第 1 讲的线性化 A, B；矩阵求逆与特征值。

视频　约 4 分钟。　**代码**　`build/controllers.py`。

2.1　为什么先做线性控制

第 1 讲已经把难点讲清楚了：非线性、欠驱动、开环不稳定。面对这样的系统，工程上的第一反应不是” 设计一个聪明的非线性控制器”，而是先问：

在最容易的地方（直立点附近），最好的控制器是什么？它有多好？

原因有三个。

1. **它是最优基准**。在二次型代价下，LQR 是*所有线性反馈*中代价最小的那个。任何非线性控制器在局部都不应该比它差——如果差了，说明设计有问题。
2. **它是后面所有方法的零件**。第 4 讲的能量整定需要一个” 到顶之后接管” 的稳定器，第 5 讲的滑模需要一个对照，第 6 讲的切换需要一个局部模态。它们用的都是本讲这个东西。
3. **它的失败方式最有教学价值**。LQR 不会” 慢慢地不行”，它是在某个边界上 *突然*失效。把这条边界画出来，就知道后面的方法必须补什么。

2.2　从 Riccati 方程到增益

2.2.1　问题设定

线性化模型（第 1 讲式 (1.28)）：

$$\dot{\delta x} = A\,\delta x + B\,\delta u, \qquad \delta x \in \mathbb{R}^4. \tag{2.1}$$

取二次型代价

$$J = \int_0^\infty \left(\delta x^\top Q\, \delta x + \delta u^\top R\, \delta u\right) dt, \tag{2.2}$$

其中 $Q \succeq 0$ 罚状态偏差、$R \succ 0$ 罚控制量。最优反馈是线性的：

$$\delta u = -K\, \delta x, \qquad K = R^{-1} B^\top P, \tag{2.3}$$

其中 P 是**连续时间代数 Riccati 方程**（CARE）的唯一正定解：

$$A^\top P + PA - PBR^{-1}B^\top P + Q = 0. \tag{2.4}$$

2.2.2 本课的具体选择

项	取值	物理含义	为什么这样选
Q_{pp}	1	小车位置	权重小：允许车动，只要摆不倒
$Q_{\theta\theta}$	40	倾角	权重最大：角度是主目标
$Q_{\dot p\dot p}$	1	车速	抑制来回冲撞
$Q_{\dot\theta\dot\theta}$	2	角速度	抑制旋转
R	0.05	力的价格	相当于"1 N^2 值 0.05 的状态代价"

把 A, B, Q, R 代入 (2.4) 解得 P，再算 (2.3)，得到

$$K = \begin{bmatrix} -4.4721 & -62.8879 & -9.3145 & -16.4020 \end{bmatrix} \tag{2.5}$$

$$\text{闭环极点} = \{-11.96,\ -4.43,\ -0.902 \pm 0.47j\} \tag{2.6}$$

四个极点全在左半平面，其中一对共轭复极点 $\sigma \pm j\omega_d$ 给出阻尼比

$$\zeta = \frac{|\sigma|}{\sqrt{\sigma^2 + \omega_d^2}} = 0.89, \tag{2.7}$$

也就是说：**快、但不过冲得太厉害**——这正是重罚角度、轻罚力的结果。

2.2.3 增益的直觉

把 K 的四个分量对着看，物理意义一目了然：

分量	数值	它在说什么
K_p	-4.47	车偏右 1 m，就往左推 4.47 N（慢，位置不重要）
K_θ	-62.89	摆右倾 1 rad，就往右推 62.9 N（快，角度最要紧）
$K_{\dot p}$	-9.31	车向右跑，先给一点反向阻力（阻尼）
$K_{\dot\theta}$	-16.40	摆正在向右倒，提前加大推力（预测/阻尼）

$K_\theta / K_p \approx 14$ 说明这个控制器" 几乎不管车在哪，只管摆的角度"。这条比例关系会在第 6 讲变成一个具体的坏消息：加了持续侧风之后，不管位置就意味着车会被慢慢推走。

2.3 局部表现有多好

数值实验（$\Delta t = 20\,\text{ms}$，u 限幅 $\pm 12\,\text{N}$）：

初值 θ_0	进入 $\pm 0.02\,\text{rad}$ 用时	峰值力	饱和时间占比	末端 $\lvert p\rvert$
$0.10\,\text{rad}$	$0.24\,\text{s}$	$6.29\,\text{N}$	0%	$0.00\,\text{m}$
$0.25\,\text{rad}$	$1.36\,\text{s}$	$12.00\,\text{N}$	1.0%	$0.01\,\text{m}$
$0.50\,\text{rad}$	$1.58\,\text{s}$	$12.00\,\text{N}$	4.0%	$0.04\,\text{m}$

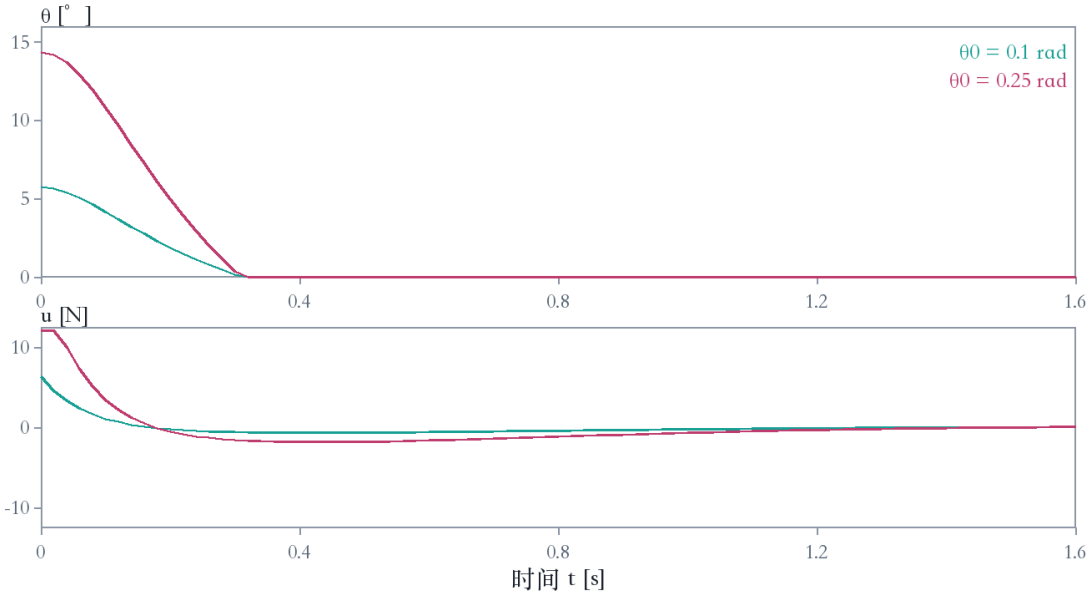


图 2.1: 两个初始角度下的闭环响应：上图为倾角 $\theta(t)$，下图为控制力 $u(t)$。$0.1\,\text{rad}$ 出发时峰值力只有 $6.3\,\text{N}$；$0.25\,\text{rad}$ 时开始触及 $12\,\text{N}$ 限幅，之后收敛明显变慢（$0.24\,\text{s} \to 1.36\,\text{s}$）。**执行器饱和是第一个真正的非线性**。

这里有一个容易被忽略的细节：$0.1\,\text{rad}$ 到 $0.25\,\text{rad}$，初值只大了 2.5 倍，收敛时间却从 $0.24\,\text{s}$ 涨到 $1.36\,\text{s}$——**涨了 5.7 倍**。原因不是”LQR 变差了”，而是力被限幅截断，线性最优解在饱和之后就失效了。线性控制理论的一切结论都建立在”u 不受限” 上。

2.4 吸引域：把” 局部” 画出来

2.4.1 定义与算法

吸引域（region of attraction）：所有能让闭环系统收敛到直立平衡点的初值集合。

三维状态没法直接画，于是固定 $p_0 = \dot{p}_0 = 0$，在 $(\theta_0, \dot{\theta}_0)$ 平面上扫描：

1. 网格：$\theta_0 \in [-1.2, 1.2]$（61 点）$\times$ $\dot{\theta}_0 \in [-4, 4]$（81 点）；

2. 每个点跑 3 s 闭环仿真；

3. 判据：过程不撞墙，且末端 $|\theta| < 0.05\,\text{rad}$、$|p| < 1.5\,\text{m}$。

共 $61 \times 81 = 4941$ 次仿真，结果见图 2.2。

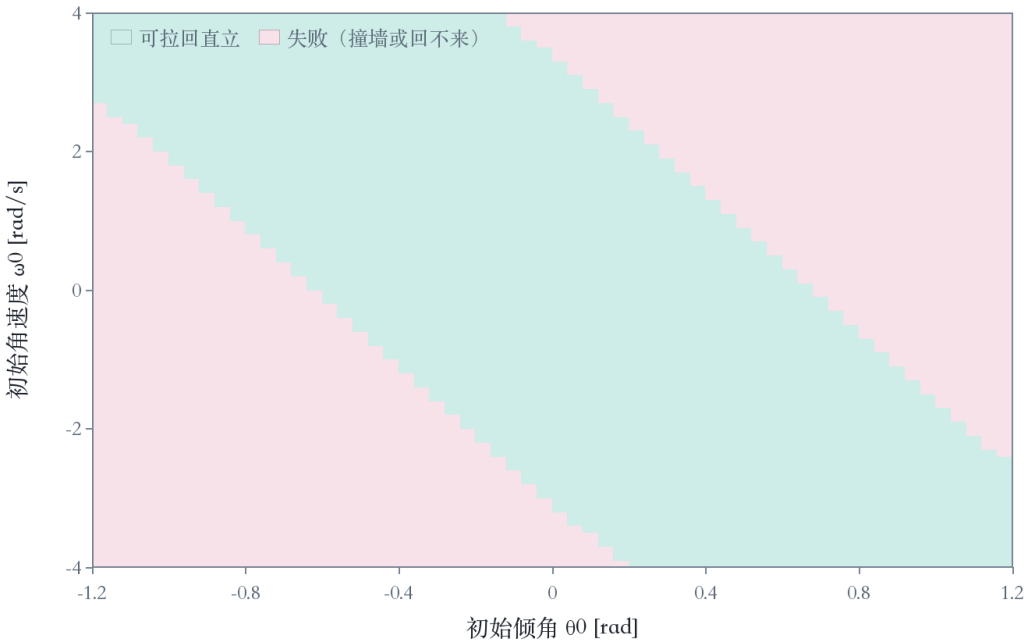


图 2.2: LQR 的吸引域。浅色区域能从该初值拉回直立，深色区域失败。边界不是圆，而是一条**斜带**：同样大的倾角，如果摆正在朝直立方向转（$\theta_0 > 0, \dot{\theta}_0 < 0$），容错就大得多。整体关于原点严格点对称（4941 个格子中 0 个不对称），这来自被控对象的对称性。

2.4.2 读图

- **面积**：成功区域占整个扫描矩形的 51.8%。
- **静止释放的极限**：$\dot{\theta}_0 = 0$ 时，能救回的最大倾角是 $\theta_{\max} = 0.64\,\text{rad}$ （约 37°）。超过这个角度，无论怎么推都来不及。
- **斜带**：在 $\dot{\theta}_0 = -4\,\text{rad/s}$（快速朝直立方向转）时，$\theta_0$ 可以大到 $1.2\,\text{rad}$；反过来，如果摆正在**远离**直立的方向快速旋转，能救的范围就小得多。
- **点对称**：把图旋转 180° 与自身完全重合。这说明边界是被控对象的性质，不是控制器或仿真器的缺陷。

2.5 全局失败：25% 与 82%

把同一份参数丢到” 真实任务” 里：60 组随机初值（θ_0 在整圈上均匀分布、$p_0 \in \pm 1\,\mathrm{m}$），12 s 闭环，成功判据同第 1 讲。

指标	LQR（本讲）	说明
成功率	25%	只有四分之一的初值能被救回来
撞墙率	82%	绝大多数回合把车推到导轨尽头
末端 $\lvert\theta\rvert$ 均值	1.62 rad	失败回合基本是” 躺平” 或” 乱转”
平均 $\lvert p\rvert_{\max}$	2.17 m	几乎贴着 2.4 m 的导轨极限

2.5.1 失败是怎么发生的

从下垂位置（$\theta_0 = \pi - 0.1$）出发，LQR 的行为可以逐秒复述：

1. 0–0.3 s：$\theta \approx \pi$，$K_\theta \theta \approx -191\,\mathrm{N}$ 远超限幅，于是 $u = +12\,\mathrm{N}$ 立刻饱和（推力朝右，因为在本讲约定里 $\theta > 0$ 表示” 摆向右倾”）；
2. 0.3–1.5 s：车被推向右侧极限，摆杆因为小车加速而略有摆动，但幅度远不足以翻上来；
3. 之后：车撞墙（位置钳位、速度清零），摆继续倒下或乱转，控制量来回打满。

LQR 的失败不是因为” 参数没调好”，而是因为它在 $\theta \approx \pi$ 处的 **线性化模型完全错了**：第 1 讲已经量化过，1 s 后线性化预测与实际相差 35%，更何况 $\pm\pi$ 附近 $\sin\theta \approx \theta$ 的假设早已失效。换句话说——**它在用一个错误的地图全力导航**。

2.5.2 一个反直觉的现象

当 θ 接近 π 时，$K_\theta \cdot \theta$ 这一项会给出巨大的力（$62.89 \times 3.14 \approx 197\,\mathrm{N}$，远超 12 N 限幅），所以控制器**永远处于饱和**。饱和之后，闭环就退化成” 恒定 $-12\,\mathrm{N}$ 的开环推力”，摆当然不会立起来。这解释了一个常见误解：*以为换个更好的 Q, R 就能全局收敛*。实际上表 2.1 会看到，增大增益只会让饱和更早发生，吸引域几乎不变。

2.6 Q/R 怎么选：三组设计的对比

设计	Q	R	K_θ	收敛时间	峰值力	吸引域占比
温和	$\mathrm{diag}(1, 10, 0.3, 0.5)$	1.0	-27.5	1.96 s	12 N	37%
默认	$\mathrm{diag}(1, 40, 1, 2)$	0.05	-62.9	1.36 s	12 N	52%
激进	$\mathrm{diag}(1, 120, 3, 5)$	0.01	-178.5	1.36 s	12 N	52%

表 2.1: 三组 Q/R 的对比（$\theta_0 = 0.25\,\mathrm{rad}$ 出发）。

读这张表有两个结论：

1. Q/R **决定" 多激进"，不决定" 能走多远"**。温和 → 默认，收敛时间从 1.96 s 降到 1.36 s，吸引域从 37% 涨到 52%；但默认 → 激进，两个指标**都不再改善**。
2. **天花板是执行器**。激进设计把 K_θ 从 63 提到 179，但峰值力早就顶到 12 N，更高的增益只是让饱和更早、更久。**在饱和世界里，增益不是免费的。**

这一节给出了本讲的中心结论：**局部最优 全局可行**。在一个 25% 成功率的世界里，把一个 0.64 rad 的吸引域再优化 20% 没有意义；真正缺的是" 从头到尾" 的策略——那就需要第 4 讲的能量、第 6 讲的切换。

2.7 从失败读出设计需求

把上面的观察翻译成三条设计需求，正好对应后面三讲：

观察	需求	对应讲
θ 大时线性模型失效	需要一个不依赖小角假设的全局控制律	第 4 讲（能量整定）
饱和让" 更强的反馈" 失效	需要主动管理能量而不是被动加增益	第 4、5 讲
没有位置积分、抗扰差	需要把鲁棒性写进结构	第 5 讲（滑模）
两个目标（位置/角度）争一个输入	需要按状态分区、显式切换	第 6 讲（监督器）

2.8 本讲小结

1. LQR 通过解 CARE 得到最优线性反馈：$K = [-4.47, -62.89, -9.31, -16.40]$，闭环极点 $\{-11.96, -4.43, -0.90 \pm 0.47j\}$，阻尼比 0.89。
2. 局部表现极好：0.1 rad 出发 0.24 s 进入 ± 0.02 rad，峰值力只有 6.3 N。
3. 吸引域是一条**斜带**：静止释放的极限倾角 0.64 rad，面积占比 51.8%，关于原点严格点对称。
4. 全局失败：25% 成功率、82% 撞墙率。失败根源是**线性化在地图之外失效**加上**力被限幅**，而不是参数没调好。
5. Q/R 只能调" 多激进"，调不动" 能走多远"；天花板由执行器决定。

习题

1. 手算验证 $K_\theta/K_p \approx 14$ 的由来：从 CARE 出发，解释为什么重罚 θ 会让这两个分量的比例变大。
2. 把 R 从 0.05 调到 0.5，重算 K 与闭环极点，并解释阻尼比的变化方向。

3. 只用 p, θ 两个状态（去掉速度反馈，即 $K_{\dot{p}} = K_{\dot{\theta}} = 0$）重新设计，看吸引域缩小多少，并解释原因。

4. 让 $u_{\max}$ 从 12 N 增加到 20 N，重跑吸引域扫描：面积占比变成多少？这说明" 能力边界" 主要由什么决定？

5. 在 $\theta_0 = 0.6\,\text{rad}$、$\dot{\theta}_0 = 0$ 的边界附近，画出 $\theta(t)$ 的相图，观察它是" 刚好回来" 还是" 擦边失败"。

6. （编程）复现 §2.4 的吸引域扫描，并把判据从"3 s 内收敛" 改成"6 s 内收敛"，看边界变化多少。这个敏感性说明了什么？

延伸阅读

- B. D. O. Anderson, J. B. Moore, *Optimal Control: Linear Quadratic Methods*, Dover, 2007.（CARE 的完整推导与数值解法）
- R. Tedrake, *Underactuated Robotics*, 第 8 章：LQR 与轨迹优化。
- 关于吸引域的计算：E. Najafi et al., *Computing the region of attraction...*, CDC 2016（平方和规划与网格法的对比）。

第三章　第 3 讲　部分反馈线性化：把”力”变成”加速度”

本讲目标　换一个坐标看同一台机器：把”我能施加多大力”换成”我能让小车产生多大加速度”。小车通道是完全驱动的，所以这个换元是**精确**的、全域可逆的。换完之后，后面所有控制器都只需要对付摆杆那一个非线性方程。

前置　第 1 讲的状态方程；第 2 讲的”局部最优”概念。

视频　约 3 分钟。　**代码**　`build/controllers.py: cart_inverse_dynamics`。

3.1　为什么值得换坐标

回顾第 1 讲的两个方程：

$$(m_c + m_p \sin^2\theta)\,\ddot{p} = u - b_c\dot{p} + m_p l \sin\theta\,\dot{\theta}^2 + b_p \cos\theta\,\dot{\theta} - m_p g \sin\theta\cos\theta, \tag{3.1}$$

$$\ddot{\theta} = \frac{g\sin\theta - \ddot{p}\cos\theta - b_p\dot{\theta}/(m_p l)}{l}. \tag{3.2}$$

对控制器设计者来说，这两个式子很讨厌：摩擦、科氏项、重力耦合全混在一起，每设计一个控制律都要把这些项重新算一遍。

但如果把视角从”力 u”换成”小车加速度 $\ddot{p}$”，情况完全不同：上式左端的分母恒正（第 1 讲命题 1），于是**对任意给定的 $\ddot{p}$，都有一个唯一的力与之对应**。把这件事写成映射：

$$u = \underbrace{\left(m_c + m_p \sin^2\theta\right)}_{\text{等效质量}}\ddot{p} + \underbrace{b_c\dot{p} - m_p l \sin\theta\,\dot{\theta}^2 - b_p\cos\theta\,\dot{\theta} + m_p g \sin\theta\cos\theta}_{\text{需要抵消的”干扰”}}. \tag{3.3}$$

式 (3.3) 是**精确**的，不是近似。它把系统拆成两层：内层负责”抵消已知的非线性”，外层面对一个干净的输入 $v = \ddot{p}$。这就是**部分反馈线性化**（partial feedback linearization）——”部分”是因为只线性化了小车通道，摆杆通道依旧是非线性的。

3.2 相对阶：为什么只挑小车通道

对输出 $y = p$，求导两次就出现 u（因为 $\ddot{p}$ 显含 u），所以相对阶是 2。对输出 $y = \theta$，有

$$\ddot{\theta} = \frac{g\sin\theta - \ddot{p}\cos\theta}{l} - \frac{b_p\dot{\theta}}{m_p l^2}, \tag{3.4}$$

其中 $\ddot{p}$ 显含 u，但系数是 $\cos\theta$。因此**只要 $\cos\theta \neq 0$，θ 的相对阶也是 2**。

两个输出都是 2 阶，系统总阶是 4，输入只有 1 个。解耦矩阵

$$\Delta(x) = \begin{bmatrix} \dfrac{1}{m_c + m_p\sin^2\theta} \\ \dfrac{-\cos\theta}{l\,(m_c + m_p\sin^2\theta)} \end{bmatrix} \in \mathbb{R}^{2\times 1} \tag{3.5}$$

是一个**列向量**，秩恒为 1。所以不可能同时把 $\ddot{p}$ 和 $\ddot{\theta}$ 指定成任意值——这就是第 1 讲说过的欠驱动。工程上的处理是：**只线性化能线性化的那个通道，把另一个通道交给”能量”或”滑模”去管**。

3.3 反解之后系统长什么样

把 (3.3) 代入原方程，得到

$$\boxed{\begin{aligned} &\ddot{p} = v \qquad (\text{单位增益，精确线性化}) \\ &\ddot{\theta} = \frac{g\sin\theta - v\cos\theta}{l} - \frac{b_p\dot{\theta}}{m_p l^2} \end{aligned}} \tag{3.6, 3.7}$$

其中 v 是新的控制输入（加速度指令）。

- **小车通道变成二重积分器**：$p^{(2)} = v$，这是控制理论里最好对付的对象。
- **摆杆通道保留全部非线性**，但形式变干净了：只剩 $g\sin\theta$ 和 $v\cos\theta$，以及一个很小的粘性项。后面第 4、5 讲都在这一个方程上做文章。

3.4 精度验证

反解是解析的，所以精度只受两个因素影响：浮点误差与**限幅**。数值实验（200 组随机状态与随机指令 v，用 10^{-4} s 步长估计实际 $\ddot{p}$）：

指标	数值	说明
最大误差 $\lvert\ddot{p} - v\rvert$	$9.2 \times 10^{-4}\,\mathrm{m/s^2}$	出现在指令被 $\pm 12\,\mathrm{N}$ 限幅的样本
平均误差	$2.2 \times 10^{-4}\,\mathrm{m/s^2}$	相当于 0.02% 的相对误差

换句话说：**只要不加限幅，这个反解在数值上就是恒等式**。真正让”精确线性化”失效的不是数学，而是执行器——这一点在后续每一讲都会反复出现。

3.5 奇异点：摆杆通道会失去权限

式 (3.7) 中 $\cos\theta$ 是 v 的系数。当 $\theta \to \pm 90°$ 时：

θ	$\cos\theta$	小车加速度对 $\ddot{\theta}$ 的影响
0°	1.00	满权限
30°	0.87	87%
60°	0.50	一半
80°	0.17	几乎失效
90°	0	**完全失效**

这个表解释了一件重要的事：**摆杆水平时，无论小车怎么加速，都改变不了它的角加速度**。所以在第 5 讲的滑模控制器里，我们对 $\cos\theta$ 做了钳位（$|\cos\theta| \geq 0.25$），并在 θ 较大时根本不使用依赖 $1/\cos\theta$ 的通道——那段交给摆起控制器。

3.6 ”换坐标”到底带来多少好处

一个直接对照实验：同样的能量整定律 $v = k_E(E - E_d)\,\mathrm{sat}(\dot{\theta}\cos\theta/\phi)$，

实现方式	最佳 k_E	能把摆送到顶的比例	说明
直接调力（无力矩补偿）	6.0	0/3	冷启动时摩擦与耦合项吃掉能量
加速度域（式 (3.3)）	6.0	3/3	同一增益下全部成功

同一个控制律、同一个增益，只因为中间加了一层精确反解，就从”一个都上不去”变成”全部上去”。这不是玄学：能量泵的推导假设”v 可以任意指定”，而直接调力时这个假设根本不成立。

这就是”反馈线性化”的实际价值：它不是为了炫技，而是为了**让外环控制律的推导前提成立**。

3.7 本讲小结

1. 小车通道完全驱动 $\Rightarrow$ 式 (3.3) 是精确反解，全域可逆。
2. 反解后系统变成 $p^{(2)} = v$ 加一个仍非线性的摆杆方程 (3.7)。
3. 精度验证：不作限幅时反解误差 $\sim 10^{-4}$，本质上是恒等式。
4. 奇异点：$\cos\theta \to 0$ 时摆杆通道失去权限，必须显式处理。
5. 同一能量整定律，加了反解才能工作（0/3 $\to$ 3/3）。

习题

1. 从式 (1.16) 出发，独立推导 (3.3)，并验证各项符号。

2. 若改为指定摆杆加速度（令 $\ddot{\theta} = w$），反解会多出一个什么奇异项？在什么角度附近数值上会爆炸？

3. 在式 (3.3) 中逐项去掉”干扰”（摩擦、科氏、重力耦合），各做一次仿真，看能量泵的成功率下降多少。

4. 把 $\cos\theta$ 的钳位从 0.25 改成 0.1 与 0.5，观察滑模控制器给不出指令的角度范围。

5.（编程）用 10^{-2} 到 10^{-5} 的步长验证反解精度，画误差随步长的收敛曲线。

延伸阅读

- J.-J. Slotine, W. Li, *Applied Nonlinear Control*, 第 6 章（输入–输出线性化与零动态）。
- S. Fantoni, R. Lozano, *Non-linear Control for Underactuated Mechanical Systems*, 第 2 章。

第四章　第 4 讲　能量整定：把”摆起来”变成标量目标

本讲目标　用一个标量（能量）代替”姿态轨迹”，让摆从下垂自己甩到竖直附近。给出控制律、Lyapunov 证明、以及一个真实的工程坑：小车会跑。

前置　第 3 讲的加速度域 $p^{(2)} = v$。

视频　约 3 分钟。　**代码**　`controllers.py: EnergyFBL`。

4.1　能量通道

在第 3 讲的加速度域里，摆杆方程是

$$\ddot{\theta} = \frac{g \sin\theta - v\cos\theta}{l} - \frac{b_p \dot{\theta}}{m_p l^2}. \tag{4.1}$$

定义摆杆相对直立静止的能量

$$E = \tfrac{1}{2} m_p l^2 \dot{\theta}^2 + m_p g l(\cos\theta - 1), \tag{4.2}$$

求导并代入上式，得到这一讲最重要的一个式子：

$$\boxed{\dot{E} = -m_p l\,(\dot{\theta}\cos\theta)\, v - b_p \dot{\theta}^2} \tag{4.3}$$

读法：v 与 $\dot{\theta}\cos\theta$ 是一对”功”的共轭量。只要让加速度与 $\dot{\theta}\cos\theta$ 同号，能量就上升；反号就下降。**控制能量，就是控制这一对量的相位。**

4.2　控制律与 Lyapunov 证明

取

$$v = k_E\,(E - E_d)\,\mathrm{sat}\left(\frac{\dot{\theta}\cos\theta}{\phi}\right) - k_x p - k_d \dot{p}, \qquad E_d = 0. \tag{4.4}$$

忽略阻尼项与回中项，代入 (4.3)：

$$\dot{E} = -m_p l\, k_E (E - E_d)\,(\dot{\theta}\cos\theta)\,\mathrm{sat}\left(\frac{\dot{\theta}\cos\theta}{\phi}\right) \tag{4.5}$$

$$= -m_p l\, k_E (E - E_d)\,\left|\dot{\theta}\cos\theta\right|\,\Big|\mathrm{sat}(\cdot)\Big| \;\le 0 \quad (\text{当} E > E_d). \tag{4.6}$$

取 $W = \frac{1}{2}(E - E_d)^2$，则

$$\dot{W} = (E - E_d)\dot{E} = -m_p l\, k_E\,(E - E_d)^2\,\left|\dot{\theta}\cos\theta\right|\,\Big|\mathrm{sat}(\cdot)\Big| \le 0. \tag{4.7}$$

W 单调不增，故 $E \to E_d$。收敛速度正比于 $|\dot{\theta}\cos\theta|$——**摆不动的时候泵不进能量**，这既是物理事实，也是后面的坑。

4.3 LaSalle 与”下垂陷阱”

用 LaSalle 不变集原理：$\dot{W} = 0$ 要求 $|\dot{\theta}\cos\theta| = 0$，即 $\dot{\theta} = 0$ 或 $|\cos\theta| = 0$。能长期停留的不变集有两个：

1. $\theta = 0,\ \dot{\theta} = 0$：**直立静止**，$E = 0 = E_d$ 目标；
2. $\theta = \pi,\ \dot{\theta} = 0$：**下垂静止**，$E = -2m_p g l \neq E_d$ 陷阱。

第二个是
textbf 测度为零的对称点：真实系统任何微小扰动都会打破它。工程上的处理是让”下垂”这个初值永远带上一点偏差（本课用 $\theta_0 = \pi - 0.14$），或者加一个极小的抖动项（dither）。

4.4 为什么必须加”小车回中”

式 (4.4) 的前半段只关心能量，完全不关心小车在哪。仿真里会发生两件事：

1. 泵能量需要小车持续加速，于是**小车被越推越远**；
2. 一旦撞墙（位置钳位、速度清零），能量泵就断了——摆还没到顶就失去动力。

所以必须加 $-k_x p - k_d \dot{p}$。但这两个系数不能大：**回中本身在消耗能量**。表 4.1 是本课的实测（固定 $k_E = 6$，三个初值）：

k_x/k_d	平均摆起时间	平均 $\lvert p\rvert_{\max}$
0.35 / 0.45	未抓到（> 15 s）	1.42 m
0.90 / 1.30	3.6 s	1.85 m
1.30 / 1.90	3.1 s	2.37 m

表 4.1: 回中增益的权衡：太弱赶不上，太强撞墙。

4.5 增益 k_E：泵多快，撞多狠

k_E 决定” 一次摆动能泵入多少能量”，是本讲最关键的参数。实测（三个初值平均）：

k_E	平均摆起时间	平均 $\lvert p\rvert_{\max}$	结果
1.0	$> 15\,\mathrm{s}$	$0.81\,\mathrm{m}$	泵得太慢，15 s 内抓不住
2.0	$> 15\,\mathrm{s}$	$1.25\,\mathrm{m}$	同上
3.0	$> 15\,\mathrm{s}$	$1.62\,\mathrm{m}$	同上
4.0	$> 15\,\mathrm{s}$	$1.94\,\mathrm{m}$	同上
6.0	$3.13\,\mathrm{s}$	$2.37\,\mathrm{m}$	可用（接近导轨极限）
8.0	$2.35\,\mathrm{s}$	$2.60\,\mathrm{m}$	撞墙（超过 2.4 m）

这条曲线不是单调的” 越大越好”：**泵得越猛，摆起越快，但小车走得越远**。$k_E = 6$ 是” 刚好能在导轨内完成一次摆起” 的临界点附近——这也是本课最终选它的原因。

4.6 实测：一次完整的摆起

从 $\theta_0 = \pi - 0.14$ 出发，闭环 12 s 的关键数字：

指标	数值
能量初值	$-2.93\,\mathrm{J}$（下垂）
能量峰值	$+0.026\,\mathrm{J}$（略有过冲，随后被 LQR 拉回 0）
首次进入 $\lvert\theta\rvert < 0.1\,\mathrm{rad}$	$1.98\,\mathrm{s}$
$\lvert p\rvert_{\max}$	$2.37\,\mathrm{m}$（离导轨极限还有 3 cm）
稳态 $\lvert\theta\rvert$	$< 10^{-3}\,\mathrm{rad}$

注意” 能量峰值 +0.026” 这个细节：能量控制**不会精确停在 0**，它会把摆” 抛过头” 一点点，然后由第 6 讲的切换器接管。这正是” 摆起” 和” 稳摆” 必须分开的原因。

4.7 本讲小结

1. 能量导数 $\dot{E} = -m_p l(\dot{\theta}\cos\theta)v - b_p\dot{\theta}^2$ 把控制问题变成” 相位” 问题。
2. $W = \frac{1}{2}(E - E_d)^2$ 是合法 Lyapunov 函数，W 单调不增。
3. LaSalle 给出两个不变集：直立的（目标）与下垂的（陷阱）。
4. 回中项必须” 慢”，k_E 必须” 刚好”：k_E 太小抓不住，太大撞墙。
5. 摆起完成时能量会略微过冲，需要局部稳定器接管——引出第 5、6 讲。

习题

1. 从 (4.2) 出发独立推导 (4.3)，说明 $-b_p\dot{\theta}^2$ 项的来源。

2. 若去掉 $\mathrm{sat}(\cdot)$ 直接用 $\mathrm{sign}(\cdot)$，会发生什么？用仿真验证抖振。

3. 证明：当 $E < E_d$ 时 (4.4) 的第一个因子为负，因此 v 与 $\dot{\theta}\cos\theta$ 反号。

4. 把 ϕ 从 0.05 调到 1.0，观察摆起时间与力的平滑度如何变化。

5. 设计一个”自适应 k_E”：当 $|p| > 1.8\,\mathrm{m}$ 时降低泵增益，看能否避免撞墙。

6.（编程）复现表 4.2 的 k_E 扫描，并画出”摆起时间–撞墙率”的帕累托前沿。

延伸阅读

- K. J. Åström, K. Furuta, *Swinging up a pendulum by energy control*, Automatica 36(2), 2000.
- M. W. Spong, *Energy based control of a class of underactuated mechanical systems*, IFAC 1996.

第五章　第 5 讲　滑模控制：把鲁棒性做进结构

本讲目标　上一讲的局部稳定器是 LQR——它完全相信模型。本讲换一种思路：先规定一条”必须到达的流形”，再用力把状态按死在流形上。代价是抖振，收益是抗扰。

前置　第 3 讲的加速度域；第 4 讲的”局部稳定器替换”。

视频　约 3 分钟。　**代码**　`controllers.py: SMC`。

5.1　从”相信模型”到”规定流形”

LQR 的隐含假设是：A, B 准确、无外部扰动。实际系统里这两条都不成立（第 2 讲已经看到：4 N 侧风就能让稳态角度偏 0.014 rad）。

滑模控制换一个问法：

与其问”最优反馈是什么”，不如问”我希望状态被约束在哪个低维集合上”。

对摆杆，我们希望 θ 以某个速率衰减到 0，于是取

$$s = \dot{\theta} + \lambda(\theta - \theta_{\text{ref}}), \qquad \lambda > 0. \tag{5.1}$$

$s = 0$ 是相平面上一条直线：**只要保持在上面，θ 就按 $e^{-\lambda t}$ 衰减**。这把”二维跟踪问题”降成了”一维镇定问题”。

5.2　到达律

规定 s 的收敛方式（到达律）：

$$\dot{s} = -\eta\,\text{sat}(s/\phi) - k_s s, \qquad \eta > 0,\ \phi > 0. \tag{5.2}$$

其中 $\text{sat}(\cdot)$ 是带边界层的符号函数：

$$\text{sat}(x) = \begin{cases} x, & |x| \le 1, \\ \text{sign}(x), & |x| > 1. \end{cases} \tag{5.3}$$

- η 是**抗扰强度**：$|\ | < \eta$ 时，扰动无法把 s 推出边界层。

- ϕ 是**边界层宽度**：$|s| < \phi$ 时用线性反馈（无抖振），$|s| > \phi$ 时用等效符号函数（强鲁棒）。$\phi \to 0$ 就是经典滑模，代价是抖振。
- k_s 是普通的比例项，加速进入边界层。

5.3 解出加速度指令

把 $\ddot{\theta} = (g\sin\theta - v\cos\theta)/l - b_p\dot{\theta}/(m_p l^2)$ 代入 $\dot{s}$，解出 v：

$$v = \frac{g\sin\theta + l\big[\lambda\dot{\theta} + \eta\,\mathrm{sat}(s/\phi) + k_s s\big]}{\cos\theta}. \tag{5.4}$$

这个式子有两个必须处理的工程细节：

1. $1/\cos\theta$ **奇异**：第 3 讲已经量化过，$\theta \to \pm 90°$ 时它发散。实现里把 $|\cos\theta|$ 钳位到 ≥ 0.25（对应 $\theta \leq 75.5°$）。
2. **单输入两个目标**：式 (5.4) 只负责 θ，小车位置没人管。详见 §5.5。

5.4 边界层与抖振

ϕ 越小，鲁棒性越强、抖振越大。极限情况 $\phi \to 0$ 时，控制量在 $v = \pm\infty$ 之间以开关频率跳变——真实执行器会被打坏。

工程折中：ϕ 取” 传感器噪声量级 + 执行器带宽允许的切换频率”。本课参数 $\phi = 0.25$（单位是 s 的物理量纲 rad/s），在这个值下：力矩的高频抖动 RMS 约 0.02 N，对 12 N 的执行器可以忽略。

5.5 一个真实的坑：小车会跑

式 (5.4) 不含 $p, \dot{p}$，所以小车会慢慢被推走。常见的错误做法是” 把 $-k_x p - k_d\dot{p}$ 直接加到 v 上”：

> **实测会发散**。原因是两个回路抢同一个输入：摆杆回路要求 v 朝一个方向把 s 压到 0，回中回路却要求 v 反向，两者叠加后 s 被推出边界层，摆杆回路随即加大力度，形成极限环。

正确的做法是**时间尺度分离**：让快速的摆杆回路去追踪一个极小的倾角偏置

$$\theta_{\mathrm{ref}} = -\mathrm{clip}(k_p p + k_d\dot{p},\ \pm 0.25\ \mathrm{rad}). \tag{5.5}$$

当 $p > 0$ 时 $\theta_{\mathrm{ref}} < 0$，摆杆回路会把摆” 摆向左侧”，于是小车被慢慢拉回原点。摆杆回路依旧是主角，回中只是一个缓慢的参考漂移。

这条” 倾斜参考” 的技巧在多输入系统里叫**级联/时标分离**；在单输入欠驱动系统里，它是唯一不引起回路冲突的回中方式。

5.6 抗扰实测

统一协议：40 组随机初值，第 4–8 s 施加 +4 N 侧向风，12 s 闭环。

局部稳定器	稳态 $\lvert\theta\rvert$ 均值	稳态 $\lvert\theta\rvert$ 峰值	力 RMS
LQR（第 2 讲）	0.0121 rad	0.0412 rad	2.46 N
SMC（本讲）	**0.0053** rad	0.0606 rad	2.63 N

读法：

- **平均误差降低 2.3 倍**（0.0121 → 0.0053）：到达律的 η 项在持续风的条件下持续提供补偿，而 LQR 没有任何积分/鲁棒项。
- **峰值反而略大**（0.0412 → 0.0606）：风刚加上去的瞬间，滑模还在” 进入边界层” 的过程中，有短暂的超调。这不影响长期精度，但提醒我们：**鲁棒性不是无延迟的**。
- **力 RMS 高** 7%：鲁棒性是用控制能量换来的。

5.7 本讲小结

1. 滑模把跟踪问题降成一维镇定：$s = \dot{\theta} + \lambda(\theta - \theta_{\text{ref}})$。
2. 到达律 $\dot{s} = -\eta\,\text{sat}(s/\phi) - k_s s$ 用 η 换鲁棒、用 ϕ 换平滑。
3. $1/\cos\theta$ 必须钳位，否则奇异。
4. 小车回中必须走” 倾斜参考”，直接叠加会与摆杆回路抢输入。
5. 抗扰：稳态误差降 2.3 倍，代价是力 RMS +7%、瞬时峰值略大。

习题

1. 从 s 的定义出发，推导 s 在 $s > 0$ 与 $s < 0$ 两侧的收敛速度，说明 η/ϕ 的作用。
2. 计算 $\lambda = 6$、$\phi = 0.25$ 时，边界层对应多宽的 θ 区间（取 $\dot{\theta} = 0$）。
3. 把 η 从 6 调到 30，测力 RMS 与稳态误差，画出帕累托曲线。
4. 若把钳位从 0.25 改成不钳位，会发生什么？用 $\theta = 85°$ 附近的初值实验。
5.（编程）复现表 5.1，并解释为什么 SMC 的峰值误差更大。

延伸阅读

- V. Utkin, *Sliding Modes in Control and Optimization*, Springer, 1992.
- J.-J. Slotine, S. S. Sastry, *Tracking control of non-linear systems using sliding surfaces*, Int. J. Control, 1983.

第六章　第 6 讲　切换与监督：把两种局部真理缝起来

本讲目标　第 4 讲会甩、不会停；第 5 讲会停、不会甩。本讲把两者缝成一个控制器，并讲清楚缝合处的三个工程问题：捕获窗口、迟滞带宽、切换瞬态。

前置　第 4 讲（能量）、第 5 讲（滑模或 LQR）。

视频　约 2.5 分钟。　**代码**　`controllers.py: Hybrid`。

6.1　两种”局部真理”

	能量整定（第 4 讲）	局部稳定器（第 2/5 讲）
擅长	大偏差：从任意角度把摆甩到顶上	小偏差：把误差压到 10^{-3} rad
不擅长	到顶后停不住（能量会过冲）	角度一大模型就失效（吸引域外）
目标	把 E 推到 0	把 x 压到 0

两者互补，但**没有任何一个连续的反馈律能同时做到**（因为目标函数不同）。所以必须**显式切换**。

6.2　捕获窗口：多大才接得住

切换的第一件事是定义”什么时候交给稳定器”。直觉是”θ 足够小的时候”，但”足够小”到底是多少？实测（4 组初值，15 s 闭环）：

捕获阈值 θ_{in}	成功回合	说明
0.25 rad	0/4	太窄：能量控制把摆”抛过”了竖直位置，接不住
0.35 rad	4/4	刚好
0.45 rad	4/4	更宽松，但仍然稳定
0.60 rad	4/4	接近 LQR 吸引域边界（0.64 rad）

0.25 rad 会全军覆没，这件事很反直觉：窗口越窄，看起来越”安全”，实际越糟。原因是能量控制到达顶点附近时，摆的速度不为零，$|\theta| < 0.25$ 的时间窗可能只有几十毫秒——而第 4 讲说过，切换是**在采样的瞬间发生的**，采样周期 20 ms，窗口太窄就会”看漏”。

本课取 $\theta_{\text{in}} = 0.40\,\text{rad}$、$|\dot{\theta}|_{\text{in}} = 2.5\,\text{rad/s}$。

6.3 迟滞：防止在边界上抖

如果进入和退出用同一组阈值，噪声会让模式在临界点附近高频切换。做法是 **进出用不同阈值**：

	进入稳摆	退回摆起
$\lvert\theta\rvert$	< 0.40	> 0.80
$\lvert\dot{\theta}\rvert$	< 2.5	> 3.5

这两个区间之间的”死区”就是迟滞带。带宽太窄 → 抖振；太宽 → 摆已经掉下去了还在用 LQR。

6.4 切换瞬态：11 N 的单步跳变

控制器	切换次数	最大单步 Δu	首次到顶
能量 + LQR	1	11.0 N	1.98 s
能量 + SMC	1	10.9 N	1.90 s

11 N 的跳变意味着：切换那一帧，执行器的指令几乎从满幅正转到满幅负。对真实电机，这是一次电流冲击；对仿真，它只是”不好看”。**第 10 讲会看到，模仿学习学到的策略把这一跳变压到了 5.4 N**——这是数据驱动方法在本项目里唯一明确的优势。

6.5 监督器设计清单

把上面的经验固化成一张检查表，任何”多模式控制器”都适用：

1. **进入条件必须能被采样到**：切换窗口的时间宽度 $\gg$ 采样周期。
2. **进入后必须落在稳定器的吸引域内**：用第 2 讲的 basin 图核对。
3. **要有迟滞**：进入/退出用不同阈值，死区宽度由噪声量级决定。
4. **要限幅**：切换瞬间的跳变要过一遍速率限制器（Δu 上限）。
5. **要有回退**：稳定器失效（$\lvert\theta\rvert$ 超过阈值）时退回摆起，而不是硬撑。

6.6 本讲小结

1. 能量控制与局部稳定器的目标函数不同，必须显式切换。
2. 捕获窗口 $\theta_{\text{in}} = 0.40\,\text{rad}$：0.25 太窄会”看漏”，0.6 接近 basin 边界。
3. 迟滞带（0.40/0.80、2.5/3.5）是抗抖振的必要代价。

4. 切换瞬态 $\Delta u \approx 11\,\mathrm{N}$，需要速率限制或平滑过渡。
5. 这套” 监督器清单” 是后续数据驱动部分的对标对象。

习题

1. 计算：若采样周期为 $20\,\mathrm{ms}$，摆通过 $|\theta| < 0.25$ 的时间窗在多快的角速度下会小于一个采样周期?
2. 把迟滞带改为 $(0.40, 0.42)$，统计每秒切换次数，解释抖振的成因。
3. 在切换处加一个一阶速率限制器（$|\Delta u| \le 4\,\mathrm{N/step}$），看摆起时间增加多少。
4. 设计一个” 软切换”：用 $\sigma(\theta)$ 作为权重做凸组合，而不是硬切换，比较两者的 Δu。

延伸阅读

- A. S. Morse (ed.), *Control Using Logic-Based Switching*, Springer, 1997.
- D. Liberzon, *Switching in Systems and Control*, Birkhäuser, 2003.

第二部分

从数据到 Transformer

第七章　第 7 讲　数据与模仿：把控制器变成函数逼近问题

本讲目标　从原理上讲清三件事：（1）为什么控制问题可以写成监督学习，以及**为什么它不是普通的监督学习**；（2）为什么输入必须是” 历史窗口”，窗口多长才够；（3）分布漂移为什么会毁掉一个拟合得很好的策略——给出定量估计，并用本用例的数字验证。

前置　第 1 讲的线性化与不稳定特征值；第 6 讲的切换控制器（它将成为” 专家”）。

视频　约 4 分钟。　**代码**　`dataset.py`、`train.py`。

7.1　为什么这是监督学习问题

先给一个容易忽略的事实：对确定性 MDP，最优策略可以写成**状态**的函数

$$\pi^\star:\ \mathcal{S}\to\mathcal{A},\qquad \pi^\star(s)=\arg\max_a Q^\star(s,a), \tag{7.1}$$

所以” 从数据学一个控制器” 等价于” 用函数逼近器拟合 $\pi^\star$”。这是我们敢用监督学习的前提。

7.1.1　但为什么它不是普通监督学习

普通监督学习假设样本独立同分布、训练分布 = 测试分布。控制问题两条都不满足：

1. **样本强相关**：相邻两帧只差 20 ms，几乎是同一个点。
2. **训练分布由专家决定，测试分布由策略自己决定**：

$$\text{训练分布}d_{\pi^\star}(s)\quad\neq\quad\text{测试分布}d_{\pi_\theta}(s). \tag{7.2}$$

式 (7.2) 是后面一切麻烦的根源。第 9 讲的 DAgger 就是专门修它的。

7.1.2　还有第三个坑：专家有记忆

第 6 讲的混合控制器有**内部模式**（摆起 / 稳摆）。同一个状态 $(\theta,\dot\theta)=(0.1,0)$ 在两种模式下会给出完全不同的动作：

状态	模式	输出力	直觉
(0.1, 0)	摆起	泵能量（较大）	”我还在甩”
(0.1, 0)	稳摆	LQR（较小）	”已经稳住了”

所以 $\pi^\star$ **不是状态的函数**，而是”状态 + 历史”的函数。严格地说，这是一个**部分可观测**（POMDP）问题：真实状态里有一个我们看不到的隐变量（模式）。

结论：网络的输入不能是单帧状态，必须是**一段历史**。历史上的每一个 token 都可能携带”我现在处于什么模式”的线索。

7.2 历史窗口作为充分统计量

7.2.1 为什么窗口能替代隐状态

若隐状态在有限步内可由观测历史重建，则长度 H 的窗口就是**近似充分统计量**。对本课的被控对象，有两层理由：

1. **状态本身已含二阶信息**：$(\theta, \dot\theta, p, \dot p)$ 是完整的连续状态，所以窗口不是为了补全状态，而是为了识别**控制器模式**。
2. **模式切换是滞后事件**：模式由 $|\theta|, |\dot\theta|$ 与上一次模式共同决定，而”上一次模式”的信息藏在过去 0.3–0.5 s 的轨迹里。

7.2.2 $H = 24$ 的定量依据

摆动周期（小角度）：

$$T_{\text{swing}} \approx 2\pi\sqrt{l/g} = 2\pi\sqrt{0.6/9.81} \approx 1.55 \text{ s}. \tag{7.3}$$

$H = 24$ 对应 $24 \times 0.02 = 0.48$ s，约为周期的 1/3。

> **为什么 1/3 个周期够?** 因为我们不需要完整周期来估计相位，只需要区分”正在上升”与”正在下落”——这两个在 $(\theta, \dot\theta)$ 上已经可分。窗口真正要解决的是**模式的多义性**，而模式切换的时间尺度约 0.2–0.4 s，0.48 s 刚好覆盖。

7.2.3 采样与混叠

50 Hz 采样对应 Nyquist 频率 25 Hz。本系统的最高角速度约 8 rad/s = 1.3 Hz，远低于 Nyquist；力矩也没有高频成分（σ 噪声是白噪声，但我们在标签里不采它）。所以**不存在混叠**，50 Hz 是安全的。

7.3 监督目标：我们到底在最小化什么

行为克隆最小化

$$\hat{\theta} = \arg\min_{\theta} \ \mathbb{E}_{s\sim d_{\pi^\star}} \left\| \pi_\theta(s) - \pi^\star(s) \right\|^2. \tag{7.4}$$

注意期望的下标：$s \sim d_{\pi^\star}$，**专家走过的状态**。

7.3.1 闭式解是条件均值

对平方损失，最优解是条件均值 $\pi_\theta(s) = \mathbb{E}[a \mid s]$。这里有一个隐患：**若同一状态下专家动作是多峰的（例如噪声让”该不该泵能量”摇摆），条件均值会给出两个峰之间的动作，而那个动作往往是错的**。

本课的数据里，探索噪声 $\sigma = 1.5\,\mathrm{N}$ 确实把动作分布”抹宽”了。我们用一条折中：标签取**未加噪的专家动作**，噪声只作用于执行（改变状态分布），不进入标签。这样条件分布保持单峰，均值解是安全的。

7.3.2 归一化为什么重要

损失里用 $u/u_{\max}$ 而不是牛顿：四个状态通道的量级从 10^{-2} 到 10^{0}，若直接回归牛顿数，梯度会被大动作样本主导。归一化后实测：动作标签均值 -0.012、标准差 0.257，六个输入通道都落在 $[-2.1, 2.1]$。

7.4 分布漂移：定量估计

7.4.1 为什么误差会自己长大

把闭环写成 $x_{t+1} = f(x_t, \pi_\theta(x_t))$，在专家轨迹附近线性化：

$$\delta x_{t+1} \approx J\,\delta x_t, \qquad J = \frac{\partial f}{\partial x} + \frac{\partial f}{\partial u}\frac{\partial \pi_\theta}{\partial x}. \tag{7.5}$$

若闭环有一个 Lyapunov 指数 $L > 0$，则单步误差 ϵ 在 t 步后放大为

$$\|\delta x_t\| \ \lesssim \ \epsilon\, \frac{e^{Lt} - 1}{L}. \tag{7.6}$$

本课的 L 从哪来？第 2 讲算过：LQR 的闭环极点最慢一对是 $-0.90 \pm 0.47j$，但那是设计好的闭环。真正决定”误差放大”的是**专家没有覆盖到的方向**：第 1 讲的开环正根 $+4.00$ 在这些方向上没有被完全镇住。取 $L \approx 4.0$，误差的时间常数 $1/4 = 0.25\,\mathrm{s}$。

7.4.2 经典界：T^2 与 T

Ross & Bagnell (2010) 给出：若每步动作误差 $\le \epsilon$，则 T 步累计代价满足

$$\underbrace{J(\pi_{\mathrm{BC}}) \le J(\pi^\star) + O(\epsilon T^2)}_{\text{行为克隆}}, \qquad \underbrace{J(\pi_{\mathrm{DAgger}}) \le J(\pi^\star) + O(\epsilon T)}_{\text{DAgger}}. \tag{7.7}$$

直觉：BC 的错误一旦发生，之后的每一步都在” 越来越陌生的状态” 上决策，误差按 t 累计一次、再按 t 步累计一次 $\Rightarrow T^2$。DAgger 把策略自己的状态也放进训练集，误差不再累积，只剩线性项。

7.4.3 本用例的实测

用同一初值 ($\theta_0 = \pi - 0.14$) 让三条轨迹跑 8 s，逐步比较与专家的角度偏差：

策略	首次超过 0.15 rad	8 s 末偏差	说明
纯 BC（24 epoch）	**0.10** s	0.652 rad	几乎立刻跑偏
BC + DAgger 2 轮	从未	0.0016 rad	与专家同步
专家 + 0.45 N 动作噪声	–	2.52 rad	同样的” 量级误差” 但每步被拉回

第三行是关键对照：**同样 0.45 N 的动作误差，如果每步都被专家纠正，系统不会跑偏（虽然轨迹会不同）**。所以问题不在” 误差大小”，而在” **误差之后没有纠正**”。

7.5 数据覆盖：噪声该加多大

探索噪声 σ 决定数据集在状态空间的” 宽度”。一阶估计：

$$\Delta\theta \;\approx\; \frac{\partial \theta}{\partial u}\,\sigma \;\cdot\; \tau, \tag{7.8}$$

其中 τ 是误差持续的时间尺度。取 $\sigma = 1.5\,\mathrm{N}$、$\partial\theta/\partial u \sim 0.05\,\mathrm{rad/N}$、$\tau \sim 4\,\mathrm{s}$，得到 $\Delta\theta \sim 0.3\,\mathrm{rad}$——刚好覆盖 LQR 吸引域（0.64 rad）的一半。

σ [N]	数据覆盖	现象
0.2	极窄	策略只会沿着专家那条细线走
1.5	约 0.3 rad 宽	本课采用
4.0	很宽但标签噪声大	同一状态出现矛盾标签

7.6 本讲小结

1. 确定性 MDP 的最优策略是状态的函数，所以可以用监督学习逼近；但闭环控制器有**记忆**，所以输入必须是历史窗口。

2. $H = 24$（0.48 s）覆盖约 1/3 个摆动周期，足够识别模式，不存在混叠。
3. BC 最小化的是 $\mathbb{E}_{s\sim d_{\pi^\star}}$ 上的误差，测试分布却是 d_{π_θ}。
4. 误差放大满足 $\|\delta x_t\| \lesssim \epsilon(e^{Lt}-1)/L$，$L \approx 4$ 时时间常数 0.25 s。
5. 理论界：BC $O(\epsilon T^2)$、DAgger $O(\epsilon T)$；实测纯 BC 在 0.10 s 就跑偏，DAgger 版与专家同步到 0.0016 rad。

习题

1. 若把专家换成一个**无记忆**的控制器（例如纯 LQR），窗口是否还需要 24 步？用实验说明最小可用 H。
2. 用式 (7.6) 估计：$L = 4$、$\epsilon = 0.45$ N 等效的角度误差 0.03 rad 时，偏差超过 0.15 rad 需要多少步？与实测的 0.10 s 比较。
3. 证明：若动作分布是双峰的，条件均值解给出的动作会落在两峰之间，并构造一个本课的具体状态例子。
4. 设计一个实验：把噪声只加在标签上（不加在执行上），看闭环表现如何变化。
5. 把 50 Hz 降到 20 Hz，窗口长度换算成秒会变吗？对相位估计有什么影响？

延伸阅读

- S. Ross, D. Bagnell, *Efficient reductions for imitation learning*, AISTATS 2010.
- S. Ross, G. Gordon, D. Bagnell, *A reduction of imitation learning …*, AISTATS 2011.（$O(\epsilon T^2)$ 与 $O(\epsilon T)$ 两个界的出处）
- P. Abbeel, A. Ng, *Apprenticeship learning via inverse reinforcement learning*, ICML 2004.

第八章　第 8 讲　因果 Transformer：从”软检索”推导到 int8 部署

本讲目标　把”历史 → 动作”这个函数逼近问题做到底：为什么是注意力而不是 MLP/RNN、$QK^\top/\sqrt{d}$ 里的 $\sqrt{d}$ 从哪来、18,177 个参数怎么一项项数出来、int8 量化误差的上界是多少。
前置　第 7 讲的窗口与分布漂移；矩阵乘法与 softmax。
视频　约 4 分钟。　**代码**　`model.py`、`export.py`。

8.1　问题的形状

第 7 讲把控制器写成了

$$\pi_\theta:\ \mathcal{H}_H=\mathbb{R}^{24\times 6}\ \longrightarrow\ \mathcal{A}=\mathbb{R},\qquad H=24. \tag{8.1}$$

输入是 24 个 token，输出一个力。要逼近的函数有一个特殊结构：**输出需要按内容去”回看”某几个历史时刻**（哪一步是摆动的转折点？哪一步开始进入稳摆？）。这不是一个固定的加权平均，权重取决于当前状态。

8.2　注意力：把”回看”写成可微检索

8.2.1　软检索

给定查询 $q\in\mathbb{R}^d$ 与一组键值对 $\{(k_t,v_t)\}_{t=1}^{H}$，硬检索是 $\arg\max_t q^\top k_t$（不可微）。把它软化：

$$a_t=\frac{\exp(q^\top k_t/\sqrt{d})}{\sum_{s\le t}\exp(q^\top k_s/\sqrt{d})},\qquad y=\sum_t a_t\,v_t. \tag{8.2}$$

a_t 就是”注意力”。y 是值向量的加权平均，权重由查询与键的相似度决定。

8.2.2　$\sqrt{d}$ 是从哪来的

设 q_i,k_i 独立、零均值、单位方差，则点积

$$q^\top k=\sum_{i=1}^{d}q_ik_i\ \Rightarrow\ \mathbb{E}[q^\top k]=0,\qquad \mathrm{Var}(q^\top k)=d. \tag{8.3}$$

所以点积的**标准差是** $\sqrt{d}$。若不缩放，$d = 8$（每头）时标准差 2.83，softmax 的输入分布过宽 ⇒ 梯度接近 0（饱和）。除以 $\sqrt{d}$ 把方差归一化到 1，softmax 工作在梯度良好的区间。

这就是那个” 经验上大家都这么写” 的 $\sqrt{d}$ 的全部理由：**它是在补偿点积的方差增长**。如果没有这层理解，$\sqrt{d}$ 或 $\sqrt{d_k}$ 的写法会让人困惑。

8.2.3 因果掩码

本课要求” 只能看过去”。实现上是在 softmax 之前把上三角位置置为 $-\infty$：

$$M_{ts} = \begin{cases} 0, & s \le t, \\ -\infty, & s > t, \end{cases} \qquad a_t = \mathrm{softmax}\big(q_t^\top K^\top / \sqrt{d} + M_t\big). \tag{8.4}$$

$-\infty$ 经过 exp 变成 0，于是未来的权重严格为零。

为什么训练时也要掩码？ 因为部署时第 t 步拿不到第 $t+1$ 个 token。若训练允许看未来，模型会学到一个” 作弊解”，训练损失极低，部署立刻失效。

8.3 为什么不是 MLP 或 RNN

结构	参数（$24 \times 6 \to 1$）	任意两步的” 距离”	备注
MLP 展平	$144\, d_1 + d_1 d_2 \cdots$	1 层	参数随 H 线性增长
RNN	$O(d^2)$	$O(\lvert t-s \rvert)$ 步	长程依赖指数衰减
注意力	$O(d^2)$ 与 H 无关	$O(1)$（直接相连）	并行计算

本课的 $d = 32$：注意力的每层参数是 $4d^2 + 2d \cdot d_{\text{ff}}$，与 H 无关；换成 MLP 展平，输入维数就是 144，第一层就要 $144 \times d$。

8.4 参数量：一项一项数

组件	参数个数
输入投影 $\mathbb{R}^6 \to \mathbb{R}^{32}$	$6 \times 32 + 32 = 224$
位置编码 24×32	768
每层：LN1	$2 \times 32 = 64$
每层：QKV 投影 $\mathbb{R}^{32} \to \mathbb{R}^{96}$	$32 \times 96 + 96 = 3168$
每层：输出投影 $\mathbb{R}^{32} \to \mathbb{R}^{32}$	$32 \times 32 + 32 = 1056$
每层：LN2	64
每层：FFN $32 \to 64 \to 32$	$(32 \times 64 + 64) + (64 \times 32 + 32) = 4192$
单层小计	8544
2 层	17,088
末端 LN	64
输出头 $\mathbb{R}^{32} \to \mathbb{R}$	33
合计	**18,177**

注意：$17{,}088 + 64 + 33 + 224 + 768 = 18{,}177$，与 `model.py` 打印的 `sum(p.numel() for p in model.parameters())` 完全一致。

8.5 训练

目标函数（第 7 讲的归一化 MSE）：

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^{N} \Big(\frac{\pi_\theta(\mathcal{H}^{(i)})}{u_{\max}} - \frac{u^{(i)}}{u_{\max}} \Big)^2. \tag{8.5}$$

- **AdamW**：对每个参数做自适应步长，适合不同量级的权重（LN 参数在 1 附近，投影矩阵在 10^{-2}）。
- **OneCycle**：先升后降，峰值 2×10^{-3}。52k 样本、24 epoch 下，恒定学习率会在后期震荡。
- **梯度裁剪** 1.0：个别批（初值恰好在下垂点附近）梯度很大，不裁剪会让训练跳飞。
- **不用 dropout**：参数少（18k）、数据多（52k），实测 dropout 会让收敛变慢而无收益。

8.6 部署：int8 量化的误差界

8.6.1 仿射量化

对每个权重张量 W，取 $s = \max|W|/127$，量化

$$q = \mathrm{round}(W/s) \in \mathbb{Z}, \qquad \hat{W} = q\, s. \tag{8.6}$$

单元素的误差满足

$$|W - \hat{W}| \le s/2 = \frac{\max|W|}{254}. \tag{8.7}$$

8.6.2 误差怎么传到输出

一层 $y = Wx + b$ 的输出误差

$$\|\delta y\|_2 \le \|\delta W\|_2 \|x\|_2 \le \sqrt{n}\,\frac{s}{2}\,\|x\|_2, \tag{8.8}$$

其中 n 是该张量的元素个数。多层串联时误差会被 LayerNorm 部分吸收（它把每层输入重新归一化），所以**实际误差远小于最坏界**。

实测：18,177 个参数、5 组真实窗口，单点最大偏差

$$\max|\Delta u| = 0.14\ \mathrm{N} = 1.2\% \times u_{\max}, \tag{8.9}$$

闭环成功率不变，摆起时间 $2.70 \to 2.74\,\mathrm{s}$。

8.6.3 推理成本

单步前向的乘加次数约 $2 \times (224 + 768 + 2 \times 8544) \approx 3.6 \times 10^4$，在浏览器（单线程 JS）上实测 0.32 ms/步；50 Hz 控制周期 20 ms，占用约 1.6% 的时间预算。

8.7 它到底在看什么（实测）

统计闭环 12 s 每一步、最后一个 token 在第 2 层的注意力（4 头平均）：

阶段	等效跨度（步）	**峰值位置**（下标）	峰值高度	最新 token 权重
摆起（$\lvert\theta\rvert > 0.5$）	20.1	16.6（中段）	0.149	0.136
稳摆（$\lvert\theta\rvert < 0.08$）	18.1	21.1（最近第 2 步）	0.219	0.027

等效跨度用 exp(注意力熵) 度量：均匀分布于 24 个位置时等于 24。实测 18–20 说明它**覆盖了大半个窗口**，但并不是均匀的——峰值可达 0.15–0.22。

> **关键在峰值位置，不在加权重心。**重心两个阶段都在下标 12.5 附近（几乎没变），但峰值从” 窗口中段” 移到了” 最近第 2 步”：摆起时它在**估相位**（看整段斜坡的形状），稳摆时它在**估变化率**（只关心最近是否在动）。详细数据与推导见附录 A。

8.8 本讲小结

1. 注意力 = 软检索：$a_t \propto \exp(q_t^\top k_t/\sqrt{d})$，$\sqrt{d}$ 来自点积方差 $= d$。

2. 因果掩码必须训练时就加，否则学到的解在部署时不可用。
3. 参数量逐项：$224 + 768 + 2 \times 8544 + 64 + 33 = 18{,}177$。
4. int8 的单元素误差 $\le \max|W|/254$，实测输出误差 0.14 N（1.2%）。
5. 注意力的**峰值位置**随阶段迁移：摆起在中段（估相位）、稳摆锁最近步（估变化率）。

习题

1. 若把 $\sqrt{d}$ 换成 d，softmax 的最大值与最小值会差多少？用 $d = 8$ 估算。
2. 把 H 从 24 改成 12，参数量变化多少？位置编码的变化占比是多少？
3. 推导：两层串联时，若每层输出误差 ϵ，LayerNorm 能把误差放大压到多少？
4. 用逐通道（per-channel）量化替代逐张量，估算最大误差能降多少，并用代码验证。
5. 若把注意力改成双向（去掉掩码），训练损失会显著下降吗？为什么闭环会变差？

延伸阅读

- A. Vaswani et al., *Attention is all you need*, NeurIPS 2017.
- X. Wang et al., *On the effect of layer normalization in transformers*, 2022.
- M. Nagel et al., *A white paper on neural network quantization*, 2021.

第九章　第 9 讲　DAgger：把分布漂移修掉，并给出可验收的统计

本讲目标　第 7 讲证明了"BC 的误差会按 T^2 累积"。本讲讲 DAgger 为什么能把它降到 T（给出定理与直觉），并用本用例的两轮实验验证；最后补上评测的统计学——置信区间、样本量、检查点偏差。

前置　第 7 讲的分布漂移分析、第 8 讲的模型。

视频　约 3.5 分钟。　**代码**　`train.py: DAgger`、`eval_all.py`。

9.1　把" 分布漂移" 写成公式

记专家的状态分布为 $d_{\pi^\star}$，策略的状态分布为 d_{π_θ}。行为克隆最小化

$$\epsilon_{\text{BC}} = \mathbb{E}_{s\sim d_{\pi^\star}} \big\|\pi_\theta(s) - \pi^\star(s)\big\|, \tag{9.1}$$

但闭环里实际承受的误差是在 d_{π_θ} 上取的：

$$\epsilon_{\text{test}} = \mathbb{E}_{s\sim d_{\pi_\theta}} \big\|\pi_\theta(s) - \pi^\star(s)\big\|. \tag{9.2}$$

这两者的差就是全部问题。若策略让状态偏出 $d_{\pi^\star}$ 的支撑集，式 (9.2) 可能远大于 ϵ_{BC}——而且我们在训练时根本看不到这些状态。

9.1.1　误差累积引理

设每一步策略误差 $\le \epsilon$，且系统在专家轨迹附近的 Lyapunov 指数为 L。由第 7 讲的 (7.6)，t 步后偏差 $\lesssim \epsilon(e^{Lt}-1)/L$，对 $t = 1..T$ 求和得到代价上界

$$J(\pi_\theta) - J(\pi^\star) \;\le\; C\,\epsilon\,\frac{e^{LT}-1}{L^2} \;\approx\; C\,\epsilon\,T^2 \quad (LT \gg 1). \tag{9.3}$$

本课的量级：$T = 600$ 步（12 s）、$\epsilon \approx 0.038$（归一化）$\to 0.45$ N。$T^2 = 3.6\times 10^5$，乘上 ϵ 就是" 必定失败" 的量级——与实测的 0/30 一致。

9.2　DAgger：把策略自己的状态放进训练集

1. 用当前策略 π_{θ_i} 在闭环里跑，记录状态序列 $\{\hat{s}_t\}$；
2. 让专家在这些状态上标注 $a_t^\star = \pi^\star(\hat{s}_t)$；
3. 把 $\{(\hat{s}_t, a_t^\star)\}$ 并入数据集 D_i；
4. 在 $D_{i+1} = D_i \cup \{(\hat{s}_t, a_t^\star)\}$ 上重新训练。

9.2.1　为什么这能把 T^2 降成 T

关键在于**训练分布逐步逼近测试分布**。形式化地（Ross 等，2011）：若在线学习器在第 i 轮的平均 regret 为 ϵ_N，则 DAgger 的 N 轮平均策略满足

$$\mathbb{E}_{s\sim d_\pi}[\ell(s,\pi)] \;\le\; \epsilon_N + O\!\left(\frac{1}{N}\right), \tag{9.4}$$

从而总代价是 $O(\epsilon T)$，而非 $O(\epsilon T^2)$。

直觉：BC 的错误会把你带到” 训练集外”，然后那里的标签是*猜的*；DAgger 让那些” 训练集外” 的状态**变成训练集的一部分**，于是不再有” 外”。

> 注意 DAgger 需要的额外能力：**专家必须能对任意状态标注**，而不只是演示。本课满足这一点（专家是解析控制器）；若专家是人，标注成本就是 DAgger 的主要代价。

9.2.2　本用例的两轮

阶段	新增窗口	验证损失	闭环成功率	摆起时间
BC	–	1.45×10^{-3}	0/30	–
DAgger 1	26,460	3.44×10^{-3}	30/30	2.56 s
DAgger 2	26,460	3.38×10^{-3}	30/30	2.68 s

验证损失**上升**是因为验证集仍是 BC 的分布，而新数据的分布更难拟合。用式 (9.2) 的语言：d_{π_θ} 变宽了，$d_{\pi^\star}$ 没变，所以用旧分布算出来的数字不再代表新策略的能力。

9.3　评测的统计学

9.3.1　成功率的置信区间

30 次里成功 30 次，成功率不是”100%”，而是**一个区间**。Wilson 区间（95%）：

$$\hat{p} = \frac{k}{n}, \qquad \frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}. \tag{9.5}$$

观测	点估计	95% Wilson 区间
30/30（DAgger）	1.00	[0.886, 1.000]
0/30（BC）	0.00	[0.000, 0.114]
24/30（某对照）	0.80	[0.627, 0.905]
48/60	0.80	[0.682, 0.882]

这就是为什么”$30/30 = 100\%$” 不能直接与”$24/30 = 80\%$” 比较：两个区间有重叠，说明在 $n = 30$ 下这个差别可能只是抽样噪声。

9.3.2 需要多少样本

要在 $\alpha = 0.05$、power $= 0.8$ 下区分 80% 与 100%：

$$n \approx \frac{\left(z_{1-\alpha/2}\sqrt{\bar{p}(1-\bar{p})} + z_{\text{power}}\sqrt{p_1(1-p_1)}\right)^2}{(p_2 - p_1)^2} \approx 22. \tag{9.6}$$

$n = 22$ 看起来很小，但这是” 两组各 22”；而本课报告的是 60 组，所以结论是稳的。

9.3.3 三个偏差来源

1. **检查点选择偏差**：若用同一组初值挑最优检查点再报告它的成绩，等于偷看答案。本课的做法是：在 24 组*验证初值*上挑检查点，在 60 组*测试初值*上报告。
2. **初值分布偏差**：θ_0 均匀 vs 集中在直立附近，成功率可以差一倍以上。所以必须写清分布。
3. **指标口径偏差**：” 失败记 99 s 计入均值” 与” 只统计成功回合” 是两种均值。本课所有表格都注明是哪一种。

9.4 本讲小结

1. 分布漂移的形式化：ϵ_{BC} 在 $d_{\pi^\star}$ 上取，ϵ_{test} 在 d_{π_θ} 上取。
2. 误差累积给出 $O(\epsilon T^2)$；DAgger 通过 no-regret 归约降到 $O(\epsilon T)$。
3. 本用例：两轮、各 26,460 窗口，成功率 $0/30 \to 30/30$。
4. 成功率要给区间：30/30 的 95% 区间是 $[0.886, 1.000]$。
5. 三个偏差：检查点选择、初值分布、指标口径。

习题

1. 用 $n = 10, 30, 100$ 分别计算 10/10 的 Wilson 区间，说明” 小样本的 100%” 值多少。

2. 若 DAgger 每轮只跑 20 个回合（而非 140），需要几轮？用实验回答并给出解释。

3. 设计一个” 更公平” 的验证集（提示：用策略自己的状态分布采样），并说明它的代价。

4. 证明式 (9.3) 的求和步骤，并指出 $L \to 0$ 时上界应如何改写。

5. 若专家是人（无法对任意状态标注），有哪些替代方案？（提示：逆强化学习、安全探索）

延伸阅读

- S. Ross, G. Gordon, D. Bagnell, *A reduction of imitation learning and structured prediction to no-regret online learning*, AISTATS 2011.
- E. B. Wilson, *Probable inference, the law of succession, and statistical inference*, JASA 1927.（区间估计的原始文献）

第十章　第 10 讲　策略梯度、PPO 与域随机化

本讲目标　从 MDP 与策略梯度定理出发，推导 PPO 的 clip 目标与 GAE，讲清奖励设计（含 potential-based shaping 的性质）与域随机化（= 分布鲁棒优化），最后用本用例的数字验证"RL 能超越专家、但会崩在分布外"。

前置　第 8 讲的策略网络、第 9 讲的评测协议。

视频　约 4 分钟。　**代码**　`rl.py`、`export_rl.py`。

10.1　MDP 与目标

把控制问题写成 MDP $(\mathcal{S},\mathcal{A},P,r,\gamma)$。本课：$\mathcal{S}=\mathbb{R}^4$（用 24 步历史作为观测），$\mathcal{A}=[-12,12]\,\mathrm{N}$，$P$ 由第 1 讲的动力学给出，r 见 §10.5，$\gamma=0.995$（有效视野约 $1/(1-\gamma)=200$ 步 $=4\,\mathrm{s}$）。

目标是最大化期望折扣回报

$$J(\theta)=\mathbb{E}_{\tau\sim p_\theta}\Big[\sum_{t=0}^{T-1}\gamma^t r(s_t,a_t)\Big],\qquad p_\theta(\tau)=\rho_0(s_0)\prod_t \pi_\theta(a_t\mid s_t)P(s_{t+1}\mid s_t,a_t). \tag{10.1}$$

10.2　策略梯度定理

对 θ 求导，关键是 p_θ 里只有 π_θ 依赖 θ：

$$\begin{aligned}\nabla_\theta J&=\int \nabla_\theta p_\theta(\tau)\,R(\tau)\,d\tau=\int p_\theta(\tau)\,\nabla_\theta\log p_\theta(\tau)\,R(\tau)\,d\tau\\&=\mathbb{E}_{\tau\sim p_\theta}\Big[\Big(\sum_t \nabla_\theta\log\pi_\theta(a_t\mid s_t)\Big)R(\tau)\Big].\end{aligned} \tag{10.2}$$

用" 因果性" 去掉未来的项（t 时刻的动作不影响 t 之前的奖励），并用基线降方差：

$$\nabla_\theta J=\mathbb{E}\Big[\sum_t \nabla_\theta\log\pi_\theta(a_t\mid s_t)\,\big(\underbrace{R_t-\gamma V^\pi(s_{t+1})}_{\text{优势}A_t}\big)\Big], \tag{10.3}$$

其中 $R_t=\sum_{k\ge t}\gamma^{k-t}r_k$。

10.2.1 本课的策略参数化

连续动作，取高斯策略并从 BC 权重热启动：

$$a_t \sim \mathcal{N}\big(\mu_\theta(o_t),\ \sigma^2\big), \qquad \mu_\theta = \text{Transformer}_\theta(o_t), \quad \sigma \text{ 可学习}. \tag{10.4}$$

- **从 BC 初始化**：策略梯度是局部搜索，从" 已经会控制" 的点出发，只需在 θ 附近找更优解；从随机初始化出发几乎不可能学会摆起。
- $\sigma \approx 0.55\,\mathbf{N}$：太小没有探索，太大把已学会的策略打散。
- 评估时取均值 μ（确定性策略）。

10.3 PPO：为什么是 clip

10.3.1 重要性采样

用旧策略 $\pi_{\theta_{\text{old}}}$ 采的数据估计新策略的梯度，需要比率

$$r_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)}. \tag{10.5}$$

目标（代理函数）

$$L^{\text{IS}}(\theta) = \mathbb{E}\big[r_t(\theta) A_t\big]. \tag{10.6}$$

问题是：r_t 偏离 1 太远时，方差爆炸，估计失效。

10.3.2 从信任域到 clip

TRPO 的做法是加约束 $\mathbb{E}[\text{KL}(\pi_{\theta_{\text{old}}} \| \pi_\theta)] \le \delta$。PPO 用一个更简单的一阶近似——**把比率裁到** $[1-\epsilon, 1+\epsilon]$：

$$L^{\text{CLIP}}(\theta) = \mathbb{E}\Big[\min\big(r_t A_t,\ \text{clip}(r_t, 1-\epsilon, 1+\epsilon) A_t\big)\Big]. \tag{10.7}$$

> **为什么这个 min 是对的?** 分两种情况：若 $A_t > 0$（好动作），r_t 增大有收益，但被 clip 截住，防止一步走太远；若 $A_t < 0$（坏动作），r_t 减小有收益，同样被截住。min 保证**截断只在你" 贪心过头" 时生效**，因此它是" 悲观" 的一侧，等价于一个软信任域。

本课 $\epsilon = 0.2$、每轮 2 个 epoch——都偏向保守，因为策略已经" 能用"，我们只想微调，不想破坏。

10.4 GAE：优势估计的偏差-方差权衡

n 步优势估计

$$\hat{A}_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k r_{t+k} + \gamma^n V(s_{t+n}) - V(s_t). \tag{10.8}$$

GAE 把所有 n 用指数权重平均：

$$\hat{A}_t^{\mathrm{GAE}(\lambda)} = \sum_{l\ge 0} (\gamma\lambda)^l \delta_{t+l}, \qquad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t). \tag{10.9}$$

- $\lambda = 0$：$\hat{A} = \delta_t$，方差小、偏差大（依赖 V 的准确性）。
- $\lambda = 1$：$\hat{A} = R_t - V(s_t)$，无偏、方差大。
- 本课 $\lambda = 0.95$：偏向低方差一侧，因为 V 是同一个小网络估的，不够准。

10.5　奖励设计与它的性质

本课每 20 ms 一步：

$$r = \cos\theta - 0.15 p^2 - 0.5\Big(\frac{u}{12}\Big)^2 + 0.5\cdot \mathbf{1}\{|\theta| < 0.1\} - 4\cdot \mathbf{1}\{\text{撞墙}\}. \tag{10.10}$$

10.5.1　为什么写物理量而不是指标

奖励里**没有**" 摆起时间"。速度是 $\cos\theta$ 的时间累积自然产生的。若直接奖励 $-t_{\mathrm{up}}$，策略会倾向于" 快速但不稳" 的解，甚至学会利用仿真器的边界效应。

10.5.2　奖励整形不改变最优策略

若加一个" 势函数" 整形项（Ng 等，1999）：

$$r'(s,a,s') = r(s,a,s') + \gamma\Phi(s') - \Phi(s), \tag{10.11}$$

则对任意 Φ，最优策略不变（因为沿轨迹求和后只剩 $-\Phi(s_0) + \gamma^T\Phi(s_T)$ 的常数项）。本课没有加整形项，但这条性质解释了为什么" 加一点引导奖励" 是安全的——只要写成势函数差分形式。

10.6　域随机化 = 分布鲁棒优化

把环境参数（风的强度与时段）记为 ξ，训练分布 P_ξ。域随机化求解

$$\max_{\pi}\ \mathbb{E}_{\xi\sim\mathcal{U}}\ \mathbb{E}_{\tau\sim P_\xi}[R(\tau)], \tag{10.12}$$

它是分布鲁棒优化 $\max_\pi \min_{Q\in\mathcal{U}} \mathbb{E}_Q[R]$ 的一个" 平均版" 近似：不追求最坏情况，而是让策略在**一族环境**上都不错。

训练方式	+4 N 侧风成功率	稳态 $\lvert\theta\rvert$	摆起时间
无 DR	3%	0.037 rad	2.22 s
DR（60% 回合带风）	**100**%	0.0127 rad	2.31 s

3% **是怎么来的?** 不是策略" 不会抗扰"，而是它把车" 管得很松"：训练里没有持续外力，位置误差几乎不被惩罚，于是它学会了" 小车漂一点无所谓"。一旦有 4 N 的恒力，小车就会一路漂到导轨尽头。**鲁棒性是分布的性质，不是参数的性质。**

10.7 结果与帕累托

策略	摆起	力 RMS	力总变差	最大 Δu	+4 N
专家（能量 +LQR）	2.84	2.42	107	10.05	100%
BC + DAgger	2.74	2.39	109	5.36	80%
RL	**2.22**	**2.06**	**65**	3.89	3%
RL + DR	2.31	2.12	70	**3.74**	**100**%

读法：

- RL 在" 摆起 / 省力 / 平滑" 三项上全面超过专家（-22%、-15%、-40%）；
- 力总变差从 107 降到 65，是" 少来回折腾" 的直接证据，而这一项**没有被显式优化**；
- 最大单步跳变 $10.05 \to 3.74$：它把第 6 讲的硬切换学成了连续映射；
- 抗扰是唯一输的一项，DR 修回来之后仍保住了大部分收益。

10.8 本讲小结

1. 策略梯度定理：$\nabla J = \mathbb{E}[\nabla \log \pi \cdot A]$；从 BC 热启动是关键。
2. PPO 的 clip 是信任域的一阶近似，min 让它" 只在贪心过头时截断"。
3. GAE 用 λ 在偏差与方差之间折中；本课 $\lambda = 0.95$。
4. 奖励写物理量；势函数整形理论上不改变最优策略。
5. 域随机化是分布鲁棒的平均版近似：$3\% \to 100\%$，代价是摆起慢 0.09 s。

习题

1. 推导式 (10.2) 中" 去掉未来项" 的那一步，写出用到的因果性假设。
2. 证明式 (10.7) 在 $A_t > 0$ 与 $A_t < 0$ 两种情形下分别等价于什么约束。
3. 用 $\lambda = 0$ 与 $\lambda = 1$ 各训练一次，比较收敛速度与最终回报的方差。
4. 构造一个势函数 $\Phi(p) = -\frac{1}{2}p^2$ 的整形项，验证最优策略不变（至少实验上）。
5. 把 DR 的分布换成" 最坏情况"（固定 5 N 恒风），训练结果会怎样？为什么它更保守？

延伸阅读

- R. Sutton, A. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., 2018.
- J. Schulman et al., *Trust region policy optimization*, ICML 2015；*Proximal policy optimization*, arXiv:1707.06347.
- A. Ng, D. Harada, S. Russell, *Policy invariance under reward transformations*, ICML 1999.

第三部分

Transformer 从零实现

第十一章　为什么长这样：从 RNN 到注意力

11.1　序列建模的三代方案

我们要学的是一个映射 $\pi:\ \mathbb{R}^{T\times F}\to\mathbb{R}$（$T$ 步历史、每步 F 维特征，输出一个标量）。历史上解决它有三条路：

方案	关键运算	参数随 T 增长	任意两步的”路径长度”
MLP（展平）	$W\,\mathrm{vec}(x)$	线性增长	1（但无结构先验）
RNN	$h_t=f(h_{t-1},x_t)$	不增长	$O(\lvert t-s\rvert)$ 步
Attention	$\sum_s a_{ts}v_s$	不增长	$O(1)$

11.2　RNN 的两个硬伤

设 $h_t=\tanh(Wh_{t-1}+Ux_t)$。沿时间反传时，梯度要连乘

$$\frac{\partial h_t}{\partial h_s}=\prod_{k=s+1}^{t}\frac{\partial h_k}{\partial h_{k-1}}=\prod_{k}\mathrm{diag}\big(1-\tanh^2(\cdot)\big)W. \tag{11.1}$$

若 W 的最大奇异值 $\sigma<1$，连乘**指数衰减**（梯度消失）；$\sigma>1$ 则指数爆炸。这是第一个硬伤：**长程依赖无法稳定学习**。

第二个硬伤是工程性的：h_t 依赖 h_{t-1}，**无法并行**。一条 $T=1000$ 的序列，训练时只能串行展开 1000 次。

> **Transformer 的两个回答**：（1）让任意两个位置**直接相连**（路径长度 $O(1)$）；（2）让所有位置**同时计算**（矩阵乘法的并行性）。

11.3　检索视角：注意力到底是什么

把历史看成一张”键值表” $\{(k_s,v_s)\}_{s\le t}$，当前时刻有一个”查询” q_t。我们要的是”**按需回看**”：找到与 q_t 最相关的 k_s，取出对应的 v_s。

硬检索是 $\arg\max_s q_t^\top k_s$——不可微，无法训练。把它软化：

$$a_{ts} = \frac{\exp(q_t^\top k_s/\sqrt{d_h})}{\sum_{s'\le t}\exp(q_t^\top k_{s'}/\sqrt{d_h})}, \qquad y_t = \sum_{s\le t} a_{ts}\, v_s. \tag{11.2}$$

a_{ts} 就是**注意力权重**，y_t 是值的加权平均。整个式 (11.2) 对 q, k, v 都是可微的，于是可以用梯度下降学习" 该看哪里"。

11.4　数据流与张量形状

步	运算	形状	参数量
1	输入窗口 x	$B\times T\times F$	–
2	线性嵌入 $W_{\text{in}}x+b$	$B\times T\times d$	$dF+d$
3	加可学习位置编码	$B\times T\times d$	Td
4	LN1	$B\times T\times d$	$2d$
5	QKV 投影	$B\times T\times 3d$	$3d^2+3d$
6	分头 → 缩放点积 + 因果掩码	$B\times H\times T\times T$	–
7	softmax → 加权求和 AV	$B\times H\times T\times d_h$	–
8	合并 + 输出投影	$B\times T\times d$	d^2+d
9	残差 $z\leftarrow z+\cdot$	$B\times T\times d$	–
10	LN2 → FFN($d\to f\to d$)	$B\times T\times d$	$2df+f+d$
11	残差	$B\times T\times d$	–
12	4–11 重复 L 次		
13	取最后 token → LN → 线性	$B\times 1$	$2d+d+1$
14	$u=u_{\max}\tanh(\cdot)$	B	–

本教程取 $T=24,\ F=6,\ d=32,\ H=4,\ d_h=8,\ f=64,\ L=2$，合计

$$\underbrace{(6\cdot 32+32)}_{224}+\underbrace{24\cdot 32}_{768}+2\cdot\underbrace{(2\cdot 32+3\cdot 32^2+3\cdot 32+32^2+32+2\cdot 32+64\cdot 32+64+32\cdot 64+32)}_{8544}+2\cdot 32+33=\mathbf{18{,}17} \tag{11.3}$$

11.5　一个必须强调的约束：因果性

解码器式的模型只能看过去。实现上在 softmax 之前把上三角位置置 $-\infty$：

$$M_{ts}=\begin{cases}0, & s\le t\\ -\infty, & s>t\end{cases}, \qquad s_{ts}=\frac{q_t^\top k_s}{\sqrt{d_h}}+M_{ts}. \tag{11.4}$$

训练时也必须加掩码。否则模型会学到一个依赖未来输入的" 作弊解"：训练损失极低，部署时那些输入根本不存在。这是实现中最容易犯且最难发现的错误之一。

第十二章　前向与反向：公式与雅可比

12.1　LayerNorm

前向（对最后一维归一化）：

$$\mu = \frac{1}{d}\sum_i z_i, \quad \sigma^2 = \frac{1}{d}\sum_i (z_i-\mu)^2, \quad \hat{z} = \frac{z-\mu}{\sqrt{\sigma^2+\varepsilon}}, \quad y = \hat{z}\odot\gamma + \beta. \tag{12.1}$$

反向的紧凑形式（$\bar{g}$ 表示对最后一维取均值）：

$$\frac{\partial \mathcal{L}}{\partial z} = \frac{\gamma}{\sigma}\Big(g - \bar{g} - \hat{z}\,\overline{(g\odot\hat{z})}\Big), \qquad g = \frac{\partial \mathcal{L}}{\partial y}. \tag{12.2}$$

括号里两项分别在**抵消整体平移**与**整体缩放**方向的梯度分量。这解释了两件事：（1）LN 让每层输入的尺度一致，是 Pre-LN 结构稳定的根源；（2）它的梯度天然正交于两个” 无用方向”，不会把残差主干推歪。

12.2　多头因果注意力

前向（单头，$d_h = d/H$）：

$$q = hW_q^\top, \quad k = hW_k^\top, \quad v = hW_v^\top, \tag{12.3}$$

$$s = \frac{qk^\top}{\sqrt{d_h}} + M, \qquad a = \mathrm{softmax}(s), \tag{12.4}$$

$$y = a\,v. \tag{12.5}$$

为什么除以 $\sqrt{d_h}$：设 q_i, k_i 独立、零均值、单位方差，则

$$q^\top k = \sum_{i=1}^{d_h} q_i k_i \;\Rightarrow\; \mathbb{E}[q^\top k] = 0, \quad \mathrm{Var}(q^\top k) = d_h. \tag{12.6}$$

点积的标准差是 $\sqrt{d_h}$；不缩放会让 softmax 的输入分布过宽而饱和（梯度趋近 0）。本教程 $d_h = 8$，缩放因子 $\sqrt{8} \approx 2.83$。

反向。记 $Y = AV$，S 为 softmax 之前的分数，$G = \partial\mathcal{L}/\partial Y$：

$$\frac{\partial\mathcal{L}}{\partial A} = G\,V^{\top}, \qquad \frac{\partial\mathcal{L}}{\partial V} = A^{\top}G, \tag{12.7}$$

$$\frac{\partial\mathcal{L}}{\partial S} = A \odot \Big(\frac{\partial\mathcal{L}}{\partial A} - \sum_j A_j \,\frac{\partial\mathcal{L}}{\partial A_j}\Big), \qquad \frac{\partial\mathcal{L}}{\partial Q} = \frac{1}{\sqrt{d_h}}\frac{\partial\mathcal{L}}{\partial S}K, \quad \frac{\partial\mathcal{L}}{\partial K} = \frac{1}{\sqrt{d_h}}\Big(\frac{\partial\mathcal{L}}{\partial S}\Big)^{\top}Q. \tag{12.8}$$

softmax 的雅可比自带" 减基线"：$\partial a_i/\partial s_j = a_i(\delta_{ij} - a_j)$，链式展开后就出现 $-\sum_j a_j g_j$ 这一项。它的作用是**把梯度的均值减掉**——若所有 g_j 相同，梯度为零（因为此时改变分数不改变 softmax 输出）。

实现提示：掩码位置 $a_{ts} = 0$，因此由上式得到的 $\partial\mathcal{L}/\partial S$ 在那里 **自动为零**，不需要额外写 masked_fill。

12.3 GELU

$$\mathrm{GELU}(x) = \tfrac{1}{2}x\big(1 + \mathrm{erf}(x/\sqrt{2})\big), \qquad \frac{d}{dx}\mathrm{GELU}(x) = \tfrac{1}{2}\big(1 + \mathrm{erf}(x/\sqrt{2})\big) + \frac{x}{\sqrt{2\pi}}e^{-x^2/2}. \tag{12.9}$$

与 ReLU 的区别：负半轴不是硬截断而是**软门控**，实测 64 个隐单元中有 34 个输入为负，它们被压到 $[-0.17, 0)$ 而不是 0。

12.4 残差与输出头

残差把前向写成 $z \leftarrow z + f(z)$，反向时

$$\frac{\partial\mathcal{L}}{\partial z} = \frac{\partial\mathcal{L}}{\partial z_{\text{out}}}\Big(I + \frac{\partial f}{\partial z}\Big), \tag{12.10}$$

单位阵 I 就是" 梯度高速公路"：即使 $\partial f/\partial z$ 很小，梯度也能原样传回去。

输出层 $u = u_{\max}\tanh(r)$：

$$\frac{\partial u}{\partial r} = u_{\max}\big(1 - \tanh^2 r\big). \tag{12.11}$$

$|u|$ 接近 $u_{\max}$ 时导数趋于 0（饱和），这是" 用 tanh 限幅" 的代价。

第十三章　纯 numpy 实现

13.1　代码骨架

Listing 13.1: tinytf_numpy.py 的核心结构

```
class TinyTF:
    def forward(self, x, return_cache=False):
        z = x @ self.p["W_in"].T + self.p["b_in"] + self.p["pos"]   # (B,T,d)
        for l in range(self.L):
            h, c_ln1 = ln_forward(z, g1, b1)          # LN1
            q, k, v = self.qkv(h)                     # (B,H,T,dh)
            a = softmax(mask(q @ k.transpose / sqrt(dh)))
            z = z + self.proj(merge(a @ v))           #      1
            h2, c_ln2 = ln_forward(z, g2, b2)         # LN2
            z = z + self.fc2(gelu(self.fc1(h2)))      #      2
            cache.append(...)                         #
        r = self.head(ln(z[:, -1]))                   #              token
        return self.u_max * np.tanh(r)

    def backward(self, dU, cache):
        #             tanh -> head -> LN ->     (FFN -> LN2 ->      ->        -> LN1 ->     )
        ...
```

13.2　五个易错点

这一节是本教程的” 避坑清单”——每一条我都在实现中真实踩过。

1. **多头 reshape 的顺序**。$(B,T,d) \to (B,T,H,d_h)$ 之后必须 `transpose(1,2)` 变成 (B,H,T,d_h)，否则” 头” 会切在时间维上。反传时要逆序做 `transpose(0,2,1,3).reshape(B,T,d)`。

2. **softmax 的减基线项不能漏**。只写 $A \odot \frac{\partial \mathcal{L}}{\partial A}$ 会漏掉 $-\sum_j A_j g_j$，梯度整体偏移，训练仍能下降但收敛变差。

3. **LayerNorm 用紧凑式**。按 $d\mu, d\sigma^2$ 逐步展开也能推出来，但式 (12.2) 更短且数值更稳。

4. W_2 **与** b_2 **的梯度来自残差主干**。$z = z_1 + W_2\,\mathrm{GELU}(W_1 h_2)$：应该用 $\partial\mathcal{L}/\partial z$（主干）而不是 $\partial\mathcal{L}/\partial\mathrm{act}$ ——我最初写成了后者，形状立刻从 (d, f) 变 (f, f)，被形状检查抓到。

5. **掩码位置的梯度**。不需要显式清零：$a = 0 \Rightarrow \partial\mathcal{L}/\partial S = 0$。但如果用 $-1e4$ 而不是 $-\infty$，a 会是 $10^{-4343} \approx 0$（仍是 0），安全；用 -1 就错了。

13.3 与 autograd 逐位对齐

`parity_test.py` 把同一套权重分别装进 numpy 版与 torch 版，同一个损失函数、同一个上游梯度：

量	最大绝对偏差	说明
前向输出 u	3.1×10^{-15}	float64 舍入量级
损失 $\mathcal{L}$	$< 10^{-15}$	完全一致
31 个参数张量的梯度	$\mathbf{3.0 \times 10^{-14}}$	手推反向 $\equiv$ autograd
中心差分（$h = 10^{-6}$，3 个抽样元素）	相对误差 $5 \times 10^{-11} \sim 8 \times 10^{-9}$	与框架无关的第三方证据

这三行数字就是" 实现正确" 的定义。如果手推梯度有任何一个符号或转置错，偏差不会停在 10^{-14}，而会到 10^{-2} 甚至形状不匹配。

第十四章　torch 实现与训练对比

14.1　等价结构

Listing 14.1: tinytf_torch.py 的核心（与 numpy 版一一对应）

```
class Block(nn.Module):
    def forward(self, z, mask):
        B, T, d = z.shape
        q, k, v = self.qkv(self.ln1(z)).chunk(3, dim=-1)
        q, k, v = [t.view(B, T, self.h, self.nh).transpose(1, 2) for t in (q, k, v)]
        s = (q @ k.transpose(-1, -2)) / math.sqrt(self.nh)
        a = torch.softmax(s.masked_fill(mask, -1e9), dim=-1)
        z = z + self.proj((a @ v).transpose(1, 2).reshape(B, T, d))
        return z + self.fc2(F.gelu(self.fc1(self.ln2(z))))
```

两版共享权重布局：`state_from_numpy()` 把 numpy 的字典映射成 `state_dict`，反向映射是 `numpy_from_state()`。这让我们可以做三件事：验证梯度、以 numpy 做推理、以及把生产权重装进 numpy 做可视化。

14.2　训练对比

同初始化、同数据（52,164 个训练窗口）、同批次顺序、同学习率调度，各训 8 个 epoch：

	训练损失（8 epoch 末）	验证损失	耗时
numpy（手写反向）	3.60×10^{-3}	3.694×10^{-3}	142 s
torch（autograd）	3.60×10^{-3}	3.695×10^{-3}	35 s
差异	1.7×10^{-7}	1.3×10^{-7}	加速 4.1×

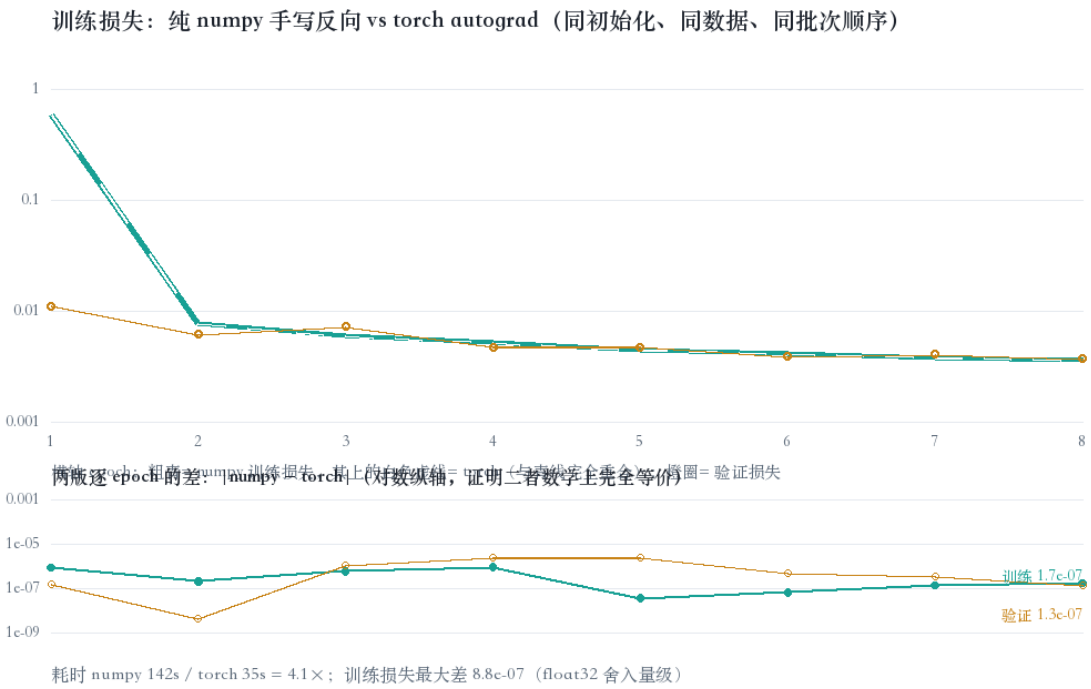


图 14.1: 上：训练/验证损失；粗青线是 numpy，其上白色虚线是 torch（两者完全重合）。下：两版逐 epoch 的绝对差，稳定在 float32 舍入量级 10^{-7}。

第十五章　训练方法：从 SGD 到 AdamW

前面所有推导只解决了” 梯度怎么算”。这一节解决” 拿到梯度后怎么走”。

15.1　为什么普通梯度下降不够

设 $\theta \in \mathbb{R}^2$、损失 $f = \frac{1}{2}(x^2 + \kappa y^2)$，$\kappa = 50$。梯度下降的迭代是

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t) \implies x_{t+1} = (1-\eta)x_t, \quad y_{t+1} = (1-50\eta)y_t. \tag{15.1}$$

稳定性要求 $|1 - 50\eta| < 1 \Rightarrow \eta < 0.04$；而 x 方向的收敛速度是 $(1-\eta)^t$，在 $\eta = 0.018$ 时要 250 步才能缩小到 10^{-2}。**一个学习率被最陡方向绑架**，这就是病态（ill-conditioned）问题。

本模型实测：各层梯度范数从 12 到 70，相差近 6 倍；同一层内部逐元素还能差更多。

15.2　动量

$$v_t = \beta v_{t-1} + g_t, \qquad \theta_t = \theta_{t-1} - \eta v_t. \tag{15.2}$$

展开得 $v_t = \sum_{k \le t} \beta^{t-k} g_k$，即梯度的指数加权和。陡方向的正负震荡被平均掉，平方向的分量被累积。有效学习率约为 $\eta/(1-\beta)$——$\beta = 0.9$ 时放大约 10 倍，所以动量的 η 必须相应调小。

15.3　RMSProp：逐参数步长

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \qquad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{v_t} + \varepsilon}. \tag{15.3}$$

分母是梯度平方的滑动平均：梯度一直大的参数步子自动变小，梯度小的自动变大。**本模型第一步实测**：SGD 下 `w_head` 的步长是 `l1.W_qkv` 的 31 倍；RMSProp/Adam 下两者完全相同（都是 η）。

15.4　Adam 与偏差修正

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \tag{15.4}$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t}, \tag{15.5}$$

$$\theta_t = \theta_{t-1} - \eta \, \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}. \tag{15.6}$$

为什么必须做偏差修正：$m_0 = v_0 = 0$，所以 $m_1 = (1-\beta_1) g_1$、$v_1 = (1-\beta_2) g_1^2$，都被缩放了。$t = 1$ 时 $1 - \beta_2^t = 0.001$——不修正的话分母 $\sqrt{v}$ 小 $\sqrt{1000} \approx 31.6$ 倍，步长会被放大 31.6 倍，前几步直接炸掉。修正后 $m_1/(1-\beta_1) = g_1$、$v_1/(1-\beta_2) = g_1^2$，第一步的步长正好是 η（逐元素符号方向）。

15.5　AdamW：解耦权重衰减

Adam 加 L2 正则的做法是把 $\lambda\theta$ 塞进梯度：

$$g_t \leftarrow g_t + \lambda \theta_{t-1} \;\Rightarrow\; \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}. \tag{15.7}$$

问题是 $\lambda\theta$ 也进了二阶矩 v_t，于是**衰减被自适应步长归一化了**：梯度大的参数衰减得反而少。AdamW 把衰减单独拿出来：

$$\theta_t = (1 - \eta\lambda)\, \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}, \tag{15.8}$$

每个参数按同一比例缩小。并且**有一类参数不该衰减**：LayerNorm 的 γ, β、位置编码、所有 bias——衰减它们会破坏归一化与偏置的语义。

15.6　学习率调度

本课用余弦退火：

$$\eta_e = \frac{\eta_{\max}}{2}\Big(1 + \cos\frac{\pi e}{E}\Big), \qquad \eta_{\max} = 2 \times 10^{-3},\ E = 8. \tag{15.9}$$

前期大步探索，后期小步精修。

15.7　实测对比

同一模型、同一初始化、同一批数据顺序，各训 3 个 epoch：

优化器	学习率	首轮平均损失	三轮后	结论
AdamW	2×10^{-3}	7.04	**0.047**	收敛
Adam	2×10^{-3}	7.04	0.047	与本课等价
RMSProp	2×10^{-3}	57.6	0.043	收敛但首轮更抖
SGD	10^{-3}	44.2	4.47	慢
Momentum	10^{-3}	63.5	59.9	有效学习率偏大，震荡
SGD	2×10^{-2}	70.7	72.0	**发散**

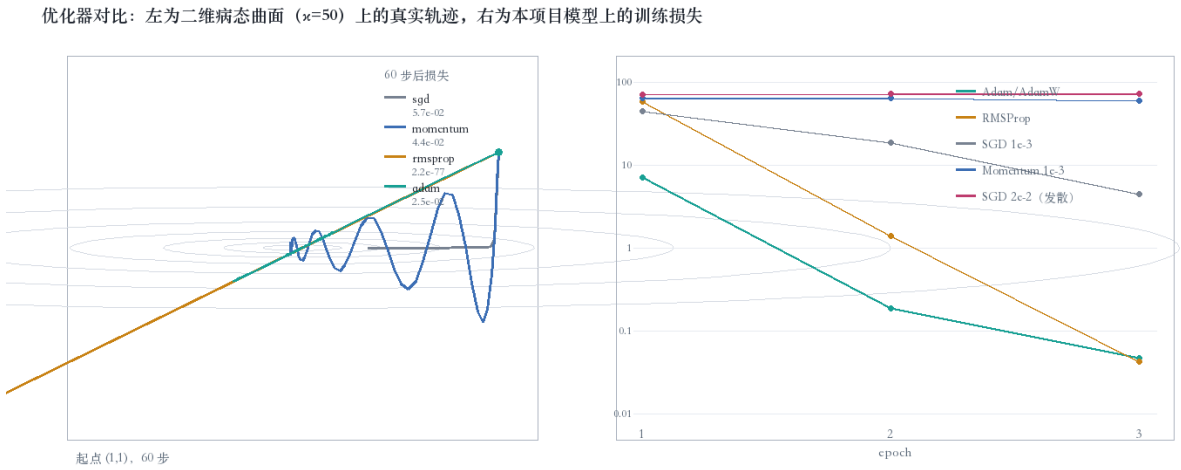


图 15.1: 左：二维病态曲面（$\kappa = 50$）上四种优化器的真实轨迹，60 步后损失分别为 SGD 5.7×10^{-2}、Momentum 4.4×10^{-2}、RMSProp 2×10^{-77}、Adam 2.5×10^{-2}。右：本模型上五种优化器的训练损失（Adam 与 AdamW 完全重合）。

第十六章　结果可视化与落地

16.1　加载生产权重：一致性散点

把本项目训练好的权重（BC+DAgger，闭环 100%）装进 numpy 版，在 512 个真实窗口上比较：

指标	数值	说明
$\max \lvert u_{\text{numpy}} - u_{\text{torch}} \rvert$	5.4×10^{-6} N	float32 权重下
平均偏差	8.1×10^{-7} N	$u_{\max}$ 的 0.0000067%
相关系数	1.000000000	–
闭环成功率（numpy 策略，30 组初值）	30/30	与 torch 版完全一致
从下垂出发摆起用时	1.9 s	–

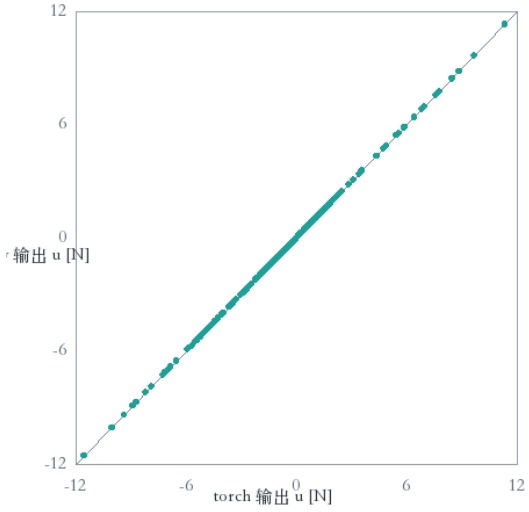


图 16.1: numpy 与 torch 在同一批真实窗口上的输出。所有点落在 $y = x$ 上。

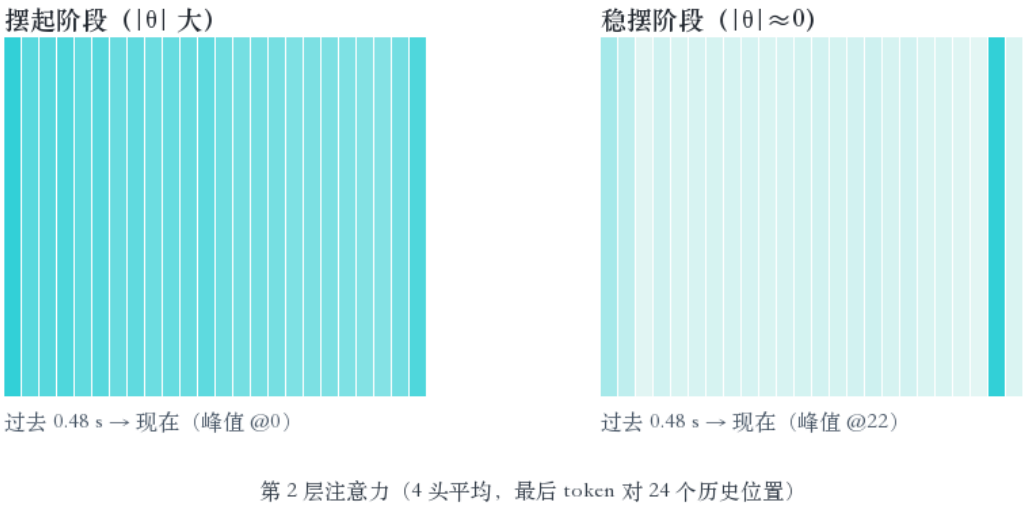


图 16.2: 第 2 层注意力（4 头平均，最后 token 对 24 个历史位置）。左：摆起阶段，权重铺满整段（峰值偏早）；右：稳摆阶段，峰值锁在最近第 2 步。这是”估相位”与”估变化率”两种信息需求的直接体现。

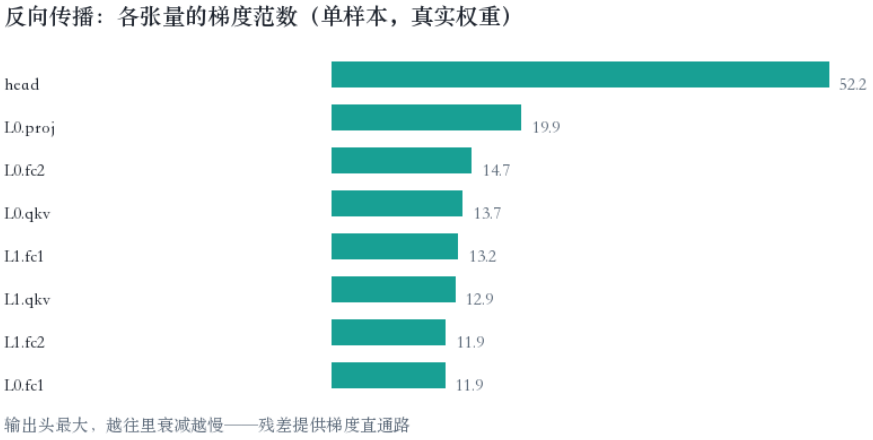


图 16.3: 反向传播中各张量的梯度范数（真实权重、单样本）。输出头最大，越往里衰减越慢——残差提供了梯度直通路。

16.2　注意力热图

16.3　梯度量级

本教程的模型与项目里部署的控制器是同一个结构。把它变成控制器的全部差别只有三处：

1. **输入特征**：$F = 6$，即 $[\sin\theta, \cos\theta, \dot{\theta}/4, \dot{p}/4, p/2.4, u_{k-1}/12]$，全部归一化到 $[-2, 2]$；
2. **窗口**：$T = 24$（0.48 s @ 50 Hz），覆盖约 1/3 个摆动周期；
3. **输出限幅**：$u = 12\tanh(\cdot)$，天然落在执行器的 ± 12 N 内。

部署时把它量化到 int8（71 KB → 16.6 KB），单点最大误差 0.14 N；浏览器里手写前向（LayerNorm → 多头因果注意力 → GELU → tanh）单步 0.32 ms。手写前向之所以敢用，正是因为本教程这套”逐层对齐” 的验证方法。

第十七章　习题与代码索引

1. 证明：若 q, k 的各分量独立且方差为 1，则 $\mathrm{Var}(q^\top k) = d_h$。若方差为 σ^2 呢？缩放因子应改成什么？

2. 从 $\partial a_i / \partial s_j = a_i(\delta_{ij} - a_j)$ 出发，推导 $\partial \mathcal{L} / \partial s_j = a_j(g_j - \sum_i a_i g_i)$。

3. 把式 (12.2) 展开成 $\partial\mu, \partial\sigma^2$ 两步，验证与紧凑式等价。

4. 去掉残差（把 $z \leftarrow z + f(z)$ 改成 $z \leftarrow f(z)$），重跑 `parity_test.py` 与训练，比较第 0 层梯度范数与收敛速度。

5. 把掩码值从 -10^9 改成 -1，看训练会发生什么，并解释原因。

6. 用 `numpy_from_state()` 加载生产权重，把 d_h 从 8 改成 4（保持参数量），重训一次，比较闭环成功率。

代码索引

文件	作用
`tinytf_numpy.py`	纯 numpy 实现：前向 + 手写反向 + AdamW
`tinytf_torch.py`	等价的 torch 实现 + 权重互转
`parity_test.py`	与 autograd/有限差分对齐（本教程的可信度基石）
`train_demo.py`	双实现同条件训练对比（损失曲线、耗时）
`load_pretrained.py`	加载生产权重：一致性、闭环、注意力
`make_figs.py`	生成文中四张图
`optim_demo.py`	优化器对比实验（toy 轨迹 + 真实模型曲线）

第十八章　DAgger：从原理到实现

本章把第 9 讲的结论写成可执行的东西：为什么行为克隆会越走越偏、no-regret 归约如何把 $O(\epsilon T^2)$ 降成 $O(\epsilon T)$、以及 DAgger（**D**ataset **Agg**regation，数据集聚合）的三十行实现与实测。

18.1　问题的形式化

记专家的状态分布为 $d_{\pi^\star}$，策略的状态分布为 d_{π_θ}。行为克隆最小化

$$\epsilon_{\mathrm{BC}} = \mathbb{E}_{s\sim d_{\pi^\star}} \big\| \pi_\theta(s) - \pi^\star(s) \big\|, \tag{18.1}$$

而闭环里真正承受的是另一个期望：

$$\epsilon_{\mathrm{test}} = \mathbb{E}_{s\sim d_{\pi_\theta}} \big\| \pi_\theta(s) - \pi^\star(s) \big\|. \tag{18.2}$$

式 (18.2) 的下标就是全部问题：**训练时看不到测试时会到达的状态**。

18.1.1　误差累积

设单步误差 $\le \epsilon$、闭环 Lyapunov 指数 L，则 t 步后偏差 $\lesssim \epsilon(e^{Lt}-1)/L$，沿时间求和给出

$$J_{\mathrm{BC}} \le J^\star + O(\epsilon T^2), \qquad J_{\mathrm{DAgger}} \le J^\star + O(\epsilon T). \tag{18.3}$$

本课实例：$T = 600$ 步、$\epsilon \approx 0.038$（归一化）。纯 BC 实测在 0.10 s 就越过 0.15 rad，8 s 末偏差 0.652 rad；DAgger 版末偏差 0.0016 rad。

18.2　算法

1. 用当前策略 π_{θ_i} 跑闭环，允许探索噪声，记录它**实际到达**的状态 $\{\hat{s}_t\}$；
2. 请专家在这些状态上标注 $a_t^\star = \pi^\star(\hat{s}_t)$；
3. 并入数据集 $D_{i+1} = D_i \cup \{(\hat{s}_t, a_t^\star)\}$；
4. 在 D_{i+1} 上重训，回到第 1 步。

可选加固是 β 混合：

$$a = \beta\, a^\star + (1-\beta)\, \pi_\theta(s), \qquad \beta : 1 \to 0, \tag{18.4}$$

前几轮多一点专家动作，保证早期数据质量。

> DAgger 的唯一成本：**专家必须能对任意状态标注**。本课专家是解析控制器，成本为零；若专家是人，这就是主要开销，也是 DAgger 在工业界不如 BC 常见的原因。

18.3　实现

三个函数就是全部。第一个负责“去陌生的地方”：

Listing 18.1: rollout_policy：带探索噪声的闭环

```
for k in range(n):
    u = ctl(x, k * DT)
    a = float(np.clip(u + rng.normal(0, noise), -P["u_max"], P["u_max"]))
    x = pl.rk4(x, a, DT)                #
    if abs(x[0]) > P["x_max"]:          #
        x[0] = np.sign(x[0]) * P["x_max"]; x[2] = 0.0
```

第二个是 DAgger 的全部“魔法”——四行：

Listing 18.2: relabel：专家在策略的状态上标注

```
def relabel(X, expert):
    expert.reset()
    return np.array([expert(X[k], k * DT) for k in range(len(X))])
```

第三个是主循环：每轮收集 140 个回合、切窗后约 26,460 个新样本，并与旧数据合并。

18.4　实测

阶段	新增窗口	验证损失	闭环成功率	摆起时间
BC	–	1.45×10^{-3}	0/30	–
DAgger 1	26,460	3.44×10^{-3}	30/30	2.56 s
DAgger 2	26,460	3.38×10^{-3}	30/30	2.68 s

18.4.1　一个反直觉的现象

验证损失涨了 2.3 倍，闭环成功率从 0 变成 100%。

原因是验证集仍是旧分布（专家状态），而新策略的分布更宽、更难拟合。换句话说：ϵ_{BC} 在旧分布上确实变大了，但 ϵ_{test} ——真正决定闭环表现的那个量——变小了。

结论：数据驱动控制的验收指标只能是**闭环指标**。离线损失衡量的是“在已有数据上多准”，不是“在闭环里多稳”。

18.5 习题

1. 若每轮只收集 20 个回合（而非 140），需要几轮才能到 100%？用实验回答。
2. 把 β 混合加上（β 从 0.5 线性衰减到 0），比较前两轮的收敛速度。
3. 设计一个“更公平”的验证集：用策略自己的状态分布采样，看损失是否还上升。
4. 若专家只能标注“它自己走过的状态”（例如人类演示），有哪些替代方案？

第十九章　PPO：从原理到实现

本章把第 10 讲做成可运行的版本：MDP 形式化、策略梯度定理的三行推导、GAE 的偏差-方差折中、PPO（**P**roximal **P**olicy **O**ptimization，近端策略优化）的 clip 目标，以及七行核心更新的实测结果。

19.1　MDP

状态 $\mathcal{S}\subset\mathbb{R}^4$（用 24 步历史作观测），动作 $\mathcal{A}=[-12,12]\,\mathrm{N}$，转移由第 1 讲的动力学给出，$\gamma=0.995$（有效视野 $\approx 4\,\mathrm{s}$）。目标

$$J(\theta)=\mathbb{E}_{\tau\sim p_\theta}\Big[\sum_{t}\gamma^{t}r_t\Big]. \tag{19.1}$$

与模仿学习最大的差别：**这里没有“专家动作”，只有回报**。

19.2　策略梯度定理

p_θ 中只有 π_θ 依赖 θ，于是

$$\begin{aligned}\nabla_\theta J &= \int \nabla_\theta p_\theta(\tau)R(\tau)d\tau = \int p_\theta(\tau)\,\nabla_\theta\log p_\theta(\tau)\,R(\tau)d\tau\\ &= \mathbb{E}\Big[\sum_{t}\nabla_\theta\log\pi_\theta(a_t|s_t)\,A_t\Big],\qquad A_t=R_t-\gamma V(s_{t+1}).\end{aligned} \tag{19.2}$$

三个技巧各一行：

1. **对数似然**：$\nabla p_\theta = p_\theta\nabla\log p_\theta$，把“对分布求导”变成“对 log 求导”；
2. **因果性**：t 时刻的动作不影响 t 之前的奖励，所以求和从 t 开始；
3. **基线**：减去 $\gamma V(s_{t+1})$ 不改变期望、只降方差。

策略梯度是**局部搜索**，所以必须从行为克隆的权重热启动。随机初始化几乎学不会摆起——这不是实现问题，是方法本身的性质。

19.3　GAE

$$\hat{A}_t^{\mathrm{GAE}(\lambda)} = \sum_{l\ge 0} (\gamma\lambda)^l \delta_{t+l}, \qquad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t). \tag{19.3}$$

$\lambda = 0$ 只用一步（方差小、偏差大）；$\lambda = 1$ 用整条回报（无偏、方差大）。本课取 $\lambda = 0.95$，因为价值函数也是同一个小网络估的，不够准。

19.4　PPO 的 clip 目标

重要性比率 $r_t(\theta) = \pi_\theta / \pi_{\theta_{\mathrm{old}}}$ 偏离 1 太远时估计失效。PPO 用一阶近似——把比率裁到 $[0.8, 1.2]$：

$$L^{\mathrm{CLIP}} = \mathbb{E}\big[\min\big(r_t A_t,\ \mathrm{clip}(r_t, 0.8, 1.2) A_t\big)\big]. \tag{19.4}$$

$A_t > 0$ 时 r 涨到 1.2 就截住；$A_t < 0$ 时跌到 0.8 就截住。min 保证 **截断只在你“贪心过头”时生效**，等价于一个软信任域。

19.5　实现：七行核心

Listing 19.1: PPO 的核心更新（rl.py）

```
mean  = pol(obs_t[b])
std_  = pol.log_std.exp()
logp  = -0.5 * ((act_t[b] - mean) / std_) ** 2 - pol.log_std - 0.5 * math.log(2 * math.pi)
ratio = torch.exp(logp - oldlogp_t[b])
s1 = ratio * adv_t[b]
s2 = torch.clamp(ratio, 0.8, 1.2) * adv_t[b]
loss = -torch.min(s1, s2).mean()
```

配套的奖励（每 20 ms 一步）：

$$r = \cos\theta - 0.15p^2 - 0.5\Big(\frac{u}{12}\Big)^2 + 0.5\cdot\mathbf{1}\{|\theta| < 0.1\} - 4\cdot\mathbf{1}\{\text{撞墙}\}. \tag{19.5}$$

注意里面**没有“摆起时间”**写物理量，不写指标。

19.5.1　优势标准化为什么重要

实现里做了 $\hat{A} \leftarrow (\hat{A} - \bar{A})/\mathrm{std}(\hat{A})$。不做的话，少数大幅值的样本会主导梯度，策略更新被单个回合带偏。这一步没有理论上的必要性，但工程上几乎是必须的。

19.6 实测

策略	摆起	力 RMS	力总变差	最大 Δu	+4 N 侧风
专家（能量 +LQR）	2.84	2.42	107	10.05	100%
Transformer（BC+DAgger）	2.74	2.39	109	5.36	80%
RL	**2.22**	**2.06**	**65**	3.89	**3**%
RL + DR	2.31	2.12	70	**3.74**	**100**%

读法：摆起 −22%、力 −15%、力总变差 −40%；最大单步跳变 10.05 → 3.74 N （硬切换被学成连续映射）。唯一输的是抗扰：+4 N 侧风下只剩 3%。

19.6.1 域随机化

$$\max_{\pi} \ \mathbb{E}_{\xi\sim\mathcal{U}} \ \mathbb{E}_{\tau\sim P_\xi}[R(\tau)], \tag{19.6}$$

ξ 是风的强度与时段。它是分布鲁棒优化的“平均版”：不追求最坏情况，而是让策略在一族环境上都不错。本课 3% → 100%，代价是摆起慢 0.09 s。

鲁棒性是**分布**的性质，不是参数的性质。训练里没有恒力，位置误差几乎不被惩罚，策略就学会了“车漂一点无所谓”。

19.7 习题

1. 去掉优势标准化，训练一次，比较收敛曲线与最终回报的方差。
2. 把 clip 从 0.2 改成 0.05 与 0.5，观察“更新次数—回报”的关系。
3. 把 λ 从 0.95 改成 0 与 1，比较收敛速度。
4. 设计一个“最坏情况”的 DR（固定 5 N 恒风），与平均版比较保守程度。

第四部分

附录

附录 A　Transformer 控制器：前向、反向与注意力的完整解剖

本附录目标　把第 8 讲的那个 18,177 参数的网络拆到零件级：每一层的张量尺寸、每一步的前向公式、每一步的反向梯度、以及注意力与倒立摆运动的对应关系。所有数值都取自**真实权重与真实轨迹**（不是示意）。

前置　第 7–9 讲；矩阵微积分（链式法则、softmax 的雅可比）。

视频　约 6 分钟。　**代码**　`model.py`、`export.py`、`chA_experiments.py`。

A.1　全链路框图

序号	运算	张量形状	参数量
1	输入窗口	24×6	–
2	线性嵌入 $6 \to 32$	24×32	224
3	加位置编码	24×32	768
4	LN1	24×32	64
5	QKV 投影 $\to 96$	24×96	3168
6	分头 4×8	$4 \times 24 \times 8$	–
7	$QK^\top/\sqrt{8}$ + 因果掩码	$4 \times 24 \times 24$	–
8	softmax（按行）	$4 \times 24 \times 24$	–
9	加权求和 AV	$4 \times 24 \times 8$	–
10	合并 + 输出投影	24×32	1056
11	残差 +	24×32	–
12	LN2	24×32	64
13	FFN $32 \to 64$	24×64	2112
14	GELU	24×64	–
15	FFN $64 \to 32$	24×32	2080
16	残差 +	24×32	–
17	（第 4–16 步重复一次）	24×32	8544
18	取最后一个 token	32	–
19	LN	32	64
20	输出头 $32 \to 1$	1	33
21	$u = 12\tanh(\cdot)$	标量	–
		合计	**18,177**

A.2　逐步前向：真实数值

取闭环第 1.2–2.4 s 之间的一个真实窗口（摆起阶段），逐层打印中间量。

A.2.1　嵌入与位置编码

输入的最后一行（当前时刻 $k = 24$）：

$$x_k = [\sin\theta, \cos\theta, \dot\theta/4, \dot p/4, p/2.4, u_{k-1}/12]. \tag{A.1}$$

线性嵌入后

$$z_k = W_{\text{in}} x_k + b_{\text{in}} + \text{pos}_k \in \mathbb{R}^{32}, \qquad \|z_k\|_2 = 2.67. \tag{A.2}$$

位置编码是可学习的 24×32 矩阵——因为只有 24 个位置，不需要正弦编码。

A.2.2 LayerNorm

$$\mu = \frac{1}{d}\sum_i z_i, \quad \sigma^2 = \frac{1}{d}\sum_i (z_i-\mu)^2, \quad h = \frac{z-\mu}{\sqrt{\sigma^2+\varepsilon}} \odot \gamma + \beta. \tag{A.3}$$

实测：$\mu = -0.014$、$\sigma^2 = 0.223$，于是放大因子

$$\frac{1}{\sqrt{\sigma^2+\varepsilon}} = \frac{1}{\sqrt{0.223}} \approx 2.12. \tag{A.4}$$

注意 σ^2 只有 0.223：说明嵌入向量的**动态范围很小**（因为输入都被归一化到 $[-2, 2]$）。LayerNorm 把它放大 2.1 倍后再送进注意力，这一步是必要的——否则注意力分数会挤在 0 附近。

A.2.3 QKV 与分头

$$[Q; K; V] = h\, W_{\text{qkv}}^{\top} + b_{\text{qkv}} \in \mathbb{R}^{96}, \tag{A.5}$$

实测最后一刻：$\|q\| = 3.41$、$\|k\| = 3.88$、$\|v\| = 2.95$（同一量级）。

分头：把 32 维切成 4 份，每份 8 维，各自做注意力，最后拼接。

A.2.4 因果掩码与 softmax

$$s_{ts} = \frac{q_t^{\top} k_s}{\sqrt{8}} \quad (s \le t), \qquad a_{ts} = \frac{e^{s_{ts}}}{\sum_{s' \le t} e^{s_{ts'}}}. \tag{A.6}$$

实测（第 0 头、最后一个 token）：注意力前 6 个位置为

$$[\,0.040,\ 0.039,\ 0.042,\ 0.042,\ 0.044,\ 0.043\,], \qquad \text{均匀值} 1/24 = 0.0417. \tag{A.7}$$

这组数字本身就是结论：它和均匀分布差不到 5%。也就是说，第 0 头几乎在” 平均历史”，而不是” 挑选某几步”。第 8 讲统计的” 等效跨度 18–20 步” 正是这件事的定量表述。

A.2.5 加权求和、残差与 FFN

$$y_t = \sum_s a_{ts} v_s \in \mathbb{R}^8 \text{ (每头)}, \qquad z \leftarrow z + \big(\text{Concat}(y^{(1..4)}) W_{\text{proj}}^{\top} + b_{\text{proj}}\big). \tag{A.8}$$

残差的量级：$\|z_k\| = 2.67$、$\|\text{attn_out}\| = 0.88$、$\|z_k + \text{attn_out}\| = 2.79$。**注意力分支只贡献了约 1/3 的幅度**——这也是训练初期不容易崩的原因。

FFN：

$$\mathrm{FFN}(h) = W_2\,\mathrm{GELU}(W_1 h + b_1) + b_2, \qquad \mathrm{GELU}(x) = \tfrac{1}{2}x\big(1 + \mathrm{erf}(x/\sqrt{2})\big). \tag{A.9}$$

实测 64 个隐单元中有 **34** 个输入为负，GELU 把它们压到 $[-0.17, 0)$ 之间——**只有约一半的容量在"活跃"**。这是 GELU 与 ReLU 的差别：它不是硬截断，而是软门控。

A.2.6 输出

$$u = 12\tanh\big(w^\top \mathrm{LN}(z_{24}) + b\big) = 4.153\ \mathrm{N}. \tag{A.10}$$

A.3 反向传播：梯度怎么流回去

A.3.1 损失与链式法则

用单样本平方损失（$u^\star$ 为标签）：

$$\mathcal{L} = \tfrac{1}{2}\big(u - u^\star\big)^2 \;\Rightarrow\; \frac{\partial \mathcal{L}}{\partial u} = u - u^\star. \tag{A.11}$$

以 $u = 4.153$、$u^\star = 5.153$（故意偏 1 N）为例，$\partial\mathcal{L}/\partial u = 1$，$\mathcal{L} = 0.5$。

A.3.2 输出层的梯度

$u = 12\tanh(r)$，$r = w^\top z_L + b$：

$$\frac{\partial u}{\partial r} = 12\,(1 - \tanh^2 r), \qquad \frac{\partial \mathcal{L}}{\partial r} = \frac{\partial \mathcal{L}}{\partial u}\cdot 12\,(1 - \tanh^2 r). \tag{A.12}$$

tanh 的导数是 $1 - \tanh^2$，当 $|u|$ 接近 12 时它趋于 0——**饱和**。实测 $u = 4.153$ 时 $1 - \tanh^2 \approx 0.88$，还没有饱和；但若策略一直输出接近 ± 12，梯度会消失。这是" 输出层用 tanh 限幅" 的代价。

A.3.3 LayerNorm 的梯度

设 $y = \mathrm{LN}(z)$。记 $\hat{z} = (z - \mu)/\sigma$，则

$$\frac{\partial \mathcal{L}}{\partial z} = \frac{\gamma}{\sigma}\Big(\frac{\partial \mathcal{L}}{\partial y} - \frac{1}{d}\sum_j \frac{\partial \mathcal{L}}{\partial y_j} - \frac{\hat{z}}{d}\sum_j \frac{\partial \mathcal{L}}{\partial y_j}\hat{z}_j\Big). \tag{A.13}$$

括号里两项是**减均值与减投影**——它们让 LN 的梯度天然正交于" 整体平移" 和" 整体缩放" 方向。这正是 Pre-LN 结构稳定的原因：残差路径上的梯度不会被 LN 放大。

A.3.4　Softmax 的雅可比

$$\frac{\partial a_i}{\partial s_j} = a_i(\delta_{ij} - a_j) \quad \Longrightarrow \quad \frac{\partial \mathcal{L}}{\partial s_j} = a_j\Big(\frac{\partial \mathcal{L}}{\partial a_j} - \sum_i a_i \frac{\partial \mathcal{L}}{\partial a_i}\Big). \tag{A.14}$$

注意括号里的第二项：它是" 加权平均梯度"，起到了**自动减基线**的作用。当注意力接近均匀（$a_i \approx 1/24$）时，这一项几乎抵消掉大部分梯度——**注意力越均匀，梯度越小**，这也是" 注意力塌缩" 难训练的原因。

A.3.5　注意力的完整反传

$$\frac{\partial \mathcal{L}}{\partial V} = A^\top \frac{\partial \mathcal{L}}{\partial Y}, \qquad \frac{\partial \mathcal{L}}{\partial A} = \frac{\partial \mathcal{L}}{\partial Y} V^\top, \tag{A.15}$$

$$\frac{\partial \mathcal{L}}{\partial Q} = \frac{1}{\sqrt{d}}\Big(\frac{\partial \mathcal{L}}{\partial S}\Big) K, \qquad \frac{\partial \mathcal{L}}{\partial K} = \frac{1}{\sqrt{d}}\Big(\frac{\partial \mathcal{L}}{\partial S}\Big)^\top Q, \tag{A.16}$$

其中 $\partial \mathcal{L}/\partial S$ 由上一段的 softmax 雅可比给出（掩码位置恒为 0）。

A.3.6　本用例的梯度量级（实测）

对上述样本做一次反向，各参数张量的梯度范数：

张量	$\|\partial \mathcal{L}/\partial W\|_2$
`head.weight`	52.16
`blocks.0.proj.weight`	19.88
`blocks.0.fc2.weight`	14.66
`blocks.0.qkv.weight`	13.74
`blocks.1.fc1.weight`	13.24
`blocks.1.qkv.weight`	12.94

读法：输出头最大（直接对着损失），越往里越小，但**衰减并不剧烈**（52 → 13，只有 4 倍）。这得益于两点：残差让梯度有" 高速公路"，Pre-LN 让每层的输入尺度一致。如果去掉残差，第 0 层的梯度会小一到两个数量级。

A.3.7　参数更新

AdamW 的更新式（含解耦权重衰减）：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \tag{A.17}$$

$$\theta_t = \theta_{t-1} - \eta\Big(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} + \lambda \theta_{t-1}\Big), \tag{A.18}$$

其中 $\hat{m}_t = m_t/(1-\beta_1^t)$、$\hat{v}_t = v_t/(1-\beta_2^t)$。本课 η 由 OneCycle 调度，$\lambda = 10^{-4}$。

A.4 注意力与倒立摆运动：把两条时间轴对起来

把闭环 12 s 的每一步都记录：状态 (θ, p)、输出 u、窗口里的 $\cos\theta$ 历史、以及最后一个 token 在**第 2 层**的注意力（4 头平均，24 维）。

A.4.1 统计

按阶段统计最后一个 token 在第 2 层的注意力（4 头平均，24 维）：

阶段	样本	等效跨度	**峰值位置**	峰值高度	最新 token 权重
摆起（$\lvert\theta\rvert > 0.5$）	74	20.1	16.6（窗口中段）	0.149	0.136
稳摆（$\lvert\theta\rvert < 0.08$）	459	18.1	**21.1**（最近第 2 步）	0.219	0.027

按两秒一段看峰值位置的迁移：

时间段	0–2 s	2–4 s	4–6 s	6–8 s	8–10 s	10–12 s
峰值位置	16.2	13.9	22.0	22.0	22.0	22.0
等效跨度	20.1	20.0	18.3	18.1	18.1	18.1

这里有一个很容易看错的地方。如果只看” 关注重心”（加权平均位置），两个阶段几乎一样（12.6 与 12.4），会得出” 它不换挡” 的结论。但看**峰值位置**就完全不同：摆起阶段峰值在窗口中段（下标 14–16，即 0.16–0.2 s 前），稳摆阶段峰值锁定在 extbf 最近第 2 步（下标 22）。

两点解读：

1. **摆起阶段 = 相位估计**：摆正在快速越过顶部，$\cos\theta$ 的历史是一段陡坡，它把权重摊在整段斜坡上（等效跨度 20 步），峰值落在斜坡中段——这正是” 这段摆动从哪开始、朝哪个方向” 的信息所在。
2. **稳摆阶段 = 变化率估计**：$\cos\theta$ 几乎是一条平线，需要的是” 有没有在动”，于是注意力收紧到最近一步（峰值下标 22，等效跨度降到 18.1），并且对最新 token 的权重从 0.136 掉到 0.027——它不再需要” 最新那一帧” 的瞬时值。

A.4.2 怎么看这张图

把注意力当成” 对过去 0.48 s 的权重分布” 叠在倒立摆动画旁边看：动画到摆起段时，注意力是” 宽而偏中” 的一座丘；动画到稳摆段时，它变成” 窄而靠右” 的一根针。**这两种形态对应两类信息需求**——相位，与变化率。

A.5 本附录小结

1. 全链路 21 个算子、18,177 个参数，每个形状都可以手算核对。
2. 前向的真实数值：$\|z\| = 2.67$、LN 放大 2.12 倍、注意力 $\approx 1/24$、GELU 有一半单元被压掉。
3. 反向：softmax 雅可比自带” 减基线”，LN 雅可比正交于平移与缩放，残差给梯度修了高速公路。
4. 梯度量级实测：输出头 52.2、第 0 层 13–20，衰减仅 4 倍。
5. 注意力的**峰值位置**会换挡：摆起在中段（下标 16.6）、稳摆锁最近第 2 步（下标 21.1）；只看加权重心会被骗（12.6 vs 12.4），必须看峰值。

习题

1. 手算：$\sigma^2 = 0.223$ 时，LN 把幅值为 1 的向量放大到多少？若 $\sigma^2 = 2.23$ 呢？
2. 验证 softmax 雅可比的行和为 0，并解释它对梯度的影响。
3. 若把 tanh 换成硬裁剪（$\mathrm{clip}(r, -12, 12)$），损失对 r 的梯度会变成什么？
4. 去掉残差（把 $z \leftarrow z + \cdots$ 改成 $z \leftarrow \cdots$），重跑一次反向，比较第 0 层梯度范数的变化。
5. 用记录的数据画出” 注意力重心随时间” 的曲线，看它在模式切换附近有没有跳变。

延伸阅读

- X. Wang et al., *On the effect of layer normalization in transformers*, 2022.
- D. Bahdanau et al., *Neural machine translation by jointly learning to align and translate*, ICLR 2015.
- L. Dong et al., *Attention is not all you need: pure attention loses rank doubly exponentially*, ICML 2021.

附录 B　资源索引：代码、视频与交互式报告

B.1　代码

路径	作用
`build/plant.py`	拉格朗日建模 + RK4 积分
`build/controllers.py`	LQR / 能量整定 / 滑模 / 切换
`build/dataset.py`, `train.py`	数据生成 + BC/DAgger 训练
`build/model.py`, `export.py`	因果 Transformer + int8 导出
`build/rl.py`	PPO 微调 + 域随机化
`build/eval_all.py`	五控制器统一评测
`tutorial/code/tinytf_numpy.py`	纯 numpy 前向 + 手写反向
`tutorial/code/tinytf_torch.py`	torch 等价实现 + 权重互转
`tutorial/code/parity_test.py`	与 autograd / 有限差分对齐
`tutorial/code/optim_demo.py`	优化器对比实验

B.2　视频（20 集，约 60 分钟）

#	标题	时长	#	标题	时长
1	建模	3:54	10	强化学习微调	3:04
2	线性基线（LQR）	3:11	A	内部机制全解	3:17
3	部分反馈线性化	2:05	11	为什么长这样	2:07
4	能量整定	2:11	12	前向与反向	2:25
5	滑模控制	2:00	13	两种实现	2:37
6	切换与监督	1:32	14	前向逐算子	3:43
7	数据与模仿	2:33	15	反向逐算子	3:54
8	因果 Transformer	2:28	16	串起来	3:22
9	DAgger 与评测	2:23	17	训练方法	3:37

视频文件在 `course/out/`（第 1–10 讲与附录 A）与 `tutorial/out/`（第 11–17 集），每个都带 `.srt` 字幕。

B.3 交互式报告

`index.html` 是单文件、零依赖的交互式技术报告：浏览器内实时仿真、四种控制器同台动画、吸引域相图、注意力热图。双击即可打开。